

随机变量的基础概念

随机变量的统计特性

随机变量的分布

离散随机变量 X 可用其**概率质量函数 (probability mass function, PMF)** $P_X(x) = P\{X = x\}$ 描述; 连续随机变量 X 可用其**累积分布函数 (cumulative distribution function, CDF)** $F_X(x) = P\{X \leq x\}$ 或**概率密度函数 (probability density function, PDF)** $f_X(x) = \frac{dF_X(x)}{dx}$ 描述。

条件于 Y 的随机变量 X 表示为 $X|Y$, 其 PMF 或 PDF、CDF 分别为

$$P_{X|Y}(x|y) = P\{X = x | Y = y\} = \frac{P_{X,Y}(x,y)}{P_Y(y)},$$
$$f_{X|Y}(x|y) = \frac{f_{X,Y}(x,y)}{f_Y(y)}, \quad F_{X|Y}(x|y) = \int_{-\infty}^x f_{X|Y}(t|y) dt$$

有全概率公式 (law of total probability)

$$P_X(x) = \sum_y P_{X|Y}(x|y)P_Y(y),$$
$$F_X(x) = \int_{-\infty}^{+\infty} F_{X|Y}(x|y)f_Y(y) dy, \quad f_X(x) = \int_{-\infty}^{+\infty} f_{X|Y}(x|y)f_Y(y) dy$$

随机变量的数字特征

使用以下数字特征来描述随机变量的统计特性:

- 均值 (mean) 或期望 (expectation)** $\mathbb{E}[X] = \int_{-\infty}^{+\infty} xf_X(x) dx$ (对离散随机变量为 $\mathbb{E}[X] = \sum_x xP_X(x)$), 描述随机变量的中心位置;
- 方差 (variance)** $\text{Var}[X] = \mathbb{E}[|X - \mathbb{E}[X]|^2]$, 描述随机变量的离散程度。

方程和均值的关系为

$$\text{Var}[X] = \mathbb{E}[|X|^2] - |\mathbb{E}[X]|^2$$

对随机变量 N 个独立同分布随机变量 X , 考虑其和 $Y = \sum_N X$, 则

- $\mathbb{E}[Y] = \mathbb{E}\left[\mathbb{E}\left[\sum_N X \mid N\right]\right] = \mathbb{E}[N]\mathbb{E}[X];$
- $\text{Var}[Y] = \mathbb{E}[N]\text{Var}[X] + \text{Var}[N]|\mathbb{E}[X]|^2.$

对条件于 Y 的随机变量 X , 类似定义:

- 条件均值 (conditional mean)** $\mathbb{E}[X|Y] = \int_{-\infty}^{+\infty} xf_{X|Y}(x|y) dx$ (对离散随机变量为 $\mathbb{E}[X|Y] = \sum_x xP_{X|Y}(x|y)$), 满足**重期望公式 (law of total expectation)**

$$\mathbb{E}[X] = \mathbb{E}_Y[\mathbb{E}_X[X|Y]]$$

- 条件方差 (conditional variance)** $\text{Var}[X|Y] = \mathbb{E}[|X - \mathbb{E}[X|Y]|^2|Y]$, 满足**全方差公式 (law of total variance)**

$$\text{Var}[X] = \text{Var}[\mathbb{E}[X|Y]] + \mathbb{E}[\text{Var}[X|Y]]$$

随机变量的特征函数

类似于 Fourier 变换, 随机变量也有其对应的**特征函数 (characteristic function)**, 它描述了随机变量在「某种意义的」频域上的分布情况。

Def. 特征函数

随机变量 X 的**特征函数 (characteristic function)** 定义为

$$\phi_X(\omega) = \mathbb{E}[e^{j\omega X}] = \int_{-\infty}^{+\infty} e^{j\omega x} f_X(x) dx$$

需要注意,

- 上述特征函数的积分中的**指数函数**为 $e^{j\omega x}$, 而常见的 Fourier 变换中的指数函数通常为 $e^{-j\omega t}$;
- 特征函数不同于一般信号的 Fourier 变换, 其积分变量是随机变量 X 的取值 x 而非时间 t , 所刻画的是 X 的**分布 (随机性)**的「频」域特性。

如果 X 为离散随机变量, 类比于 DTFT 与 z 变换的关系, 随机变量也有**母函数 (moment generating function, MGF)**。同样, 不同于常见的 z 变换表述, 此处求和使用的指数函数为 z^x 而非 z^{-x} 。

Def. 母函数

离散随机变量 X 的**母函数 (moment generating function, MGF)** 定义为

$$G_X(z) = \mathbb{E}[z^X] = \sum_x z^x P_X(x)$$

X 的**特征函数**可以表示为

$$\phi_X(\omega) = G_X(e^{j\omega})$$

特别地, $X \in \mathbb{Z}$ 时, 母函数成为幂级数或 Laurent 级数的形式。

随机变量的相互关系

随机变量的独立

两个随机变量 X 和 Y 相互**独立 (independent)**, 如果对于任意 x 和 y , 都有

$$f_{X,Y}(x,y) = f_X(x)f_Y(y) \quad \text{或} \quad P_{X,Y}(x,y) = P_X(x)P_Y(y)$$

即, X 的取值不影响 Y 的取值, 反之亦然。

随机变量的相关

相关描述两个随机变量之间的线性关系, 即寻找 $Y \simeq \alpha X$ 的关系。为此, 考虑**均方误差 (MSE)**:

$$\text{MSE} = \mathbb{E}[(Y - \alpha X)^2]$$

我们希望寻找 $\arg \min_{\alpha} \text{MSE}$, 因此令

$$\frac{\partial \text{MSE}}{\partial \alpha} = \frac{\partial}{\partial \alpha} \mathbb{E}[(Y - \alpha X)^2] = 0$$

直接**交换求导与求期望**两个微积分过程, 得到

$$\mathbb{E}[-2X(Y - \alpha X)] = 0 \implies \alpha = \frac{\mathbb{E}[XY]}{\mathbb{E}[X^2]}$$

Def. 相关

两个随机变量 X 和 Y 之积的期望 $\mathbb{E}[XY]$ 即称为二者的**相关 (correlation)**。

相关具有**双线性 (bilinear)**性质, 即对于任意常数 a, b , 有

$$\begin{cases} \mathbb{E}[(aX_1 + bX_2)Y] = a\mathbb{E}[X_1Y] + b\mathbb{E}[X_2Y], \\ \mathbb{E}[X(aY_1 + bY_2)] = a\mathbb{E}[XY_1] + b\mathbb{E}[XY_2] \end{cases}$$

Def. 协方差

两个随机变量 X 和 Y 的**协方差 (covariance)** 定义为

$$\text{Cov}(X, Y) = \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])] = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y]$$

显然, 协方差也具有**双线性**性质, 并且 $\text{Cov}(X, X) = \text{Var}(X)$ 。

两个随机变量 X 和 Y 独立, 意味着

$$f_{X,Y}(x,y) = f_X(x)f_Y(y) \quad \text{或} \quad P_{X,Y}(x,y) = P_X(x)P_Y(y)$$

而相关只描述两个随机变量之间的线性关系, 两个随机变量 X 和 Y 不相关, 仅代表

$$\text{Cov}[X, Y] = 0 \quad \text{i.e.} \quad \mathbb{E}[XY] = \mathbb{E}[X]\mathbb{E}[Y]$$

显然, 独立性蕴含不相关性, 但反之不然。

考虑随机变量 X 和 Y 的内积空间, 定义内积为

$$\langle X, Y \rangle = \mathbb{E}[XY]$$

则范数即为

$$\|X\| = \sqrt{\langle X, X \rangle} = \sqrt{\mathbb{E}[X^2]}$$

这样, Y 在 X 方向上的投影为

$$\text{proj}_X Y = \frac{\langle X, Y \rangle}{\|X\|^2} X = \frac{\mathbb{E}[XY]}{\mathbb{E}[X^2]} X$$

与前面通过最小化 MSE 得到的结果一致。

进一步地, 考虑多个随机变量 $X_1, X_2, \dots, X_n$, 记 Y 在这些变量张成的子空间上的投影为

$$\text{proj}_{X_1, X_2, \dots, X_n} Y = \alpha_1 X_1 + \alpha_2 X_2 + \dots + \alpha_n X_n = \sum_{i=1}^n \alpha_i X_i = \vec{\alpha}^T \vec{X}$$

于是 $\vec{\alpha} = \arg \min_{\vec{\alpha}} \mathbb{E}[(Y - \vec{\alpha}^T \vec{X})^2]$, 而

$$\begin{aligned} \mathbb{E}[(Y - \vec{\alpha}^T \vec{X})^2] &= \mathbb{E}[(Y - \vec{\alpha}^T \vec{X})^T (Y - \vec{\alpha}^T \vec{X})] \\ &= \mathbb{E}[(Y - \vec{X}^T \vec{\alpha})^T (Y - \vec{X}^T \vec{\alpha})] \\ &= \mathbb{E}[Y^2] - \mathbb{E}[Y^T \vec{X}^T] \vec{\alpha} - \vec{\alpha}^T \mathbb{E}[\vec{X} Y] + \vec{\alpha}^T \mathbb{E}[\vec{X} \vec{X}^T] \vec{\alpha} \end{aligned}$$

对 $\vec{\alpha}$ 求梯度并令其为零, 即

$$\nabla_{\vec{\alpha}} \mathbb{E}[(Y - \vec{\alpha}^T \vec{X})^2] \Big|_{\vec{\alpha} = \vec{a}} = -\mathbb{E}[\vec{X} Y] - \mathbb{E}[\vec{X} Y] + 2\mathbb{E}[\vec{X} \vec{X}^T] \vec{a} = 0$$

故

$$\vec{a} = (\mathbb{E}[\vec{X} \vec{X}^T])^{-1} \mathbb{E}[\vec{X} Y]$$

即, Y 与 $\vec{X}$ 各元素的相关对应着其在 $\vec{X}$ 张成的子空间上的投影系数。

$$\mathbb{E}[g(X)(X - \mu)] = \sigma^2 \mathbb{E}[g'(X)]$$

Gauss 分布的**特征函数**为

$$\phi_X(\omega) = \mathbb{E}[\exp(\mathbb{J}\omega X)] = \exp\left(\mathbb{J}\mu\omega - \frac{\sigma^2\omega^2}{2}\right)$$

► 均匀分布

称连续随机变量 X 服从**均匀分布 (uniform distribution)**, 如果其概率密度函数为

$$f_X(x) = \begin{cases} \frac{1}{b-a}, & a \leq x \leq b \\ 0, & \text{otherwise} \end{cases}$$

记为 $X \sim \mathcal{U}(a, b)$, 其中 $a < b$ 。

$$\text{若 } X \sim \mathcal{U}(a, b), \text{ 则 } \mathbb{E}[X] = \frac{a+b}{2}, \quad \text{Var}[X] = \frac{(b-a)^2}{12}.$$

均匀分布的**特征函数**为

$$\phi_X(\omega) = \mathbb{E}[\exp(\mathbb{J}\omega X)] = \frac{e^{\mathbb{J}\omega b} - e^{\mathbb{J}\omega a}}{\mathbb{J}\omega(b-a)}$$

► 指数分布

称连续随机变量 X 服从**指数分布 (exponential distribution)**, 如果其概率密度函数为

$$f_X(x) = \begin{cases} \lambda e^{-\lambda x}, & x \geq 0 \\ 0, & x < 0 \end{cases}$$

记为 $X \sim \text{Exp}(\lambda)$, 其中 $\lambda > 0$ 。

若 $X \sim \text{Exp}(\lambda)$, 则

- $\mathbb{E}[X] = \frac{1}{\lambda}$, $\text{Var}[X] = \frac{1}{\lambda^2}$, **n 阶矩**为 $\mathbb{E}[X^n] = \frac{n!}{\lambda^n}$ 。
- X 具有**无记忆性 (memoryless)**, 即对于任意 $s, t \geq 0$, 有 $P\{X > s+t \mid X > s\} = P\{X > t\}$ 。

指数分布的**特征函数**为

$$\phi_X(\omega) = \mathbb{E}[\exp(\mathbb{J}\omega X)] = \frac{\lambda}{\lambda - \mathbb{J}\omega}$$

■ 典型离散随机变量

► Poisson 分布

称离散随机变量 X 服从**Poisson 分布 (Poisson distribution)**, 如果其概率质量函数为

$$P_X(k) = \frac{\lambda^k e^{-\lambda}}{k!}, \quad k = 0, 1, 2, \dots$$

记为 $X \sim \text{Poisson}(\lambda)$, 其中 $\lambda > 0$ 。

若 $X \sim \text{Poisson}(\lambda)$, 则

- $\mathbb{E}[X] = \text{Var}[X] = \lambda$, **n 阶矩**为 $\mathbb{E}[X^n] = \sum_{i=1}^n S(n, i) \lambda^i$, 其中 $S(n, i)$ 为 **Stirling 数 (Stirling numbers)**。
- X 个独立同 **Bernoulli 分布 (p)** 随机变量之和服从参数为 λp 的 Poisson 分布。

Poisson 分布的**特征函数**为

$$\phi_X(\omega) = \mathbb{E}[\exp(\mathbb{J}\omega X)] = \exp\left(\lambda(e^{\mathbb{J}\omega} - 1)\right)$$

即**母函数**为

$$G_X(z) = \mathbb{E}[z^X] = \exp(\lambda(z - 1))$$

► Bernoulli 分布

称离散随机变量 X 服从**Bernoulli 分布 (Bernoulli distribution)**, 如果其概率质量函数为

$$P_X(k) = \begin{cases} p, & k = 1 \\ 1-p, & k = 0 \end{cases}$$

► 常见分布及其性质

■ 典型连续随机变量

► Gauss 分布

称连续随机变量 X 服从 **Gauss 分布 (Gaussian distribution)**, 如果其概率密度函数为

$$f_X(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$$

记为 $X \sim \mathcal{N}(\mu, \sigma^2)$, 其中 $\mu \in \mathbb{R}$, $\sigma^2 > 0$ 。

若 $X \sim \mathcal{N}(\mu, \sigma^2)$, 则

- $\mathbb{E}[X] = \mu$, $\text{Var}[X] = \sigma^2$ 。
- **绝对值 $|X|$** 的均值为

$$\begin{aligned} \mathbb{E}[|X|] &= \int_{-\infty}^{\infty} |x| f_X(x) dx = \frac{1}{\sqrt{2\pi}\sigma} \left(\int_{-\infty}^0 -xe^{-\frac{(x-\mu)^2}{2\sigma^2}} dx + \int_0^{\infty} xe^{-\frac{(x-\mu)^2}{2\sigma^2}} dx \right) \\ &= \mu \left(1 - 2\Phi\left(-\frac{\mu}{\sigma}\right) \right) + \frac{2\sigma}{\sqrt{2\pi}} \exp\left(-\frac{\mu^2}{2\sigma^2}\right) \end{aligned}$$

其中 $\Phi(x)$ 是标准 Gauss 分布的分布函数。特别地, 当 $\mu = 0$ 时, 有

$$\mathbb{E}[|X|] = \frac{2\sigma}{\sqrt{2\pi}}, \quad \text{亦即 } |X - \mu| \text{ 或 } \text{偏离半径的均值为 } \mathbb{E}[|X - \mu|] = \frac{2\sigma}{\sqrt{2\pi}}.$$

- **奇数阶中心矩**均为零, **偶数阶中心矩**为 $\mathbb{E}[(X - \mu)^{2n}] = \sigma^{2n} (2n - 1)!!$ 。
- 对可微函数 $g(\cdot)$, 有 **Stein 公式 (Stein's lemma)**

记为 $X \sim \begin{pmatrix} 1 & 0 \\ p & 1-p \end{pmatrix}$, 其中 $0 < p < 1$ 。

若 $X \sim \begin{pmatrix} 1 & 0 \\ p & 1-p \end{pmatrix}$, 则 $\mathbb{E}[X] = p$, $\text{Var}[X] = p(1-p)$ 。

Bernoulli 分布的**母函数**为

$$G_X(z) = \mathbb{E}[z^X] = pz + 1 - p$$

► 二项分布

称离散随机变量 X 服从**二项分布 (binomial distribution)**, 如果其概率质量函数为

$$P_X(k) = \binom{n}{k} p^k (1-p)^{n-k}, \quad k = 0, 1, 2, \dots, n$$

记为 $X \sim \mathcal{B}(n, p)$, 其中 n 为正整数, $0 < p < 1$ 。

若 $X \sim \mathcal{B}(n, p)$, 则

- $\mathbb{E}[X] = np$, $\text{Var}[X] = np(1-p)$ 。
- X 个独立同 **Bernoulli 分布** (q) 随机变量之和服从参数为 (n, pq) 的二项分布。

二项分布的**母函数**为

$$G_X(z) = \mathbb{E}[z^X] = (pz + 1 - p)^n$$

► 几何分布

称离散随机变量 X 服从**几何分布 (geometric distribution)**, 如果其概率质量函数为

$$P_X(k) = (1-p)^{k-1}p, \quad k = 1, 2, \dots$$

记为 $X \sim \text{Geometric}(p)$, 其中 $0 < p < 1$ 。

若 $X \sim \text{Geometric}(p)$, 则

- $\mathbb{E}[X] = \frac{1}{p}$, $\text{Var}[X] = \frac{1-p}{p^2}$ 。
- X 具有**无记忆性**, 即对 $\forall m, n \geq 1$, $P\{X > m+n \mid X > m\} = P\{X > n\}$ 。
- X 个独立同 **几何分布** $\text{Geometric}(q)$ 随机变量之和服从参数为 pq 的几何分布。
- X 个独立同 **指数分布** $\text{Exp}(\lambda)$ 随机变量之和服从参数为 λp 的指数分布。

几何分布的**母函数**为

$$G_X(z) = \mathbb{E}[z^X] = \frac{pz}{1 - (1-p)z}, \quad |z| < \frac{1}{1-p}$$

► 负二项分布

称离散随机变量 X 服从**负二项分布 (negative binomial distribution)**, 如果其概率质量函数为

$$P_X(k) = \binom{k-1}{n-1} p^n (1-p)^{k-n}, \quad k = n, n+1, n+2, \dots$$

记为 $X \sim \text{NegBin}(n, p)$, 其中 n 为正整数, $0 < p < 1$ 。**几何分布**是 $n=1$ 的负二项分布。

若 $X \sim \text{NegBin}(n, p)$, 则 $\mathbb{E}[X] = \frac{n}{p}$, $\text{Var}[X] = \frac{n(1-p)}{p^2}$ 。

负二项分布的**母函数**为

$$G_X(z) = \mathbb{E}[z^X] = \left(\frac{pz}{1 - (1-p)z} \right)^n, \quad |z| < \frac{1}{1-p}$$

多元相关的矩阵分析

对于一组随机变量 $\vec{X} = (X_1 \ X_2 \ \dots \ X_n)^T$, 其**相关矩阵 (correlation matrix)**定义为

$$\mathbf{R}_{\vec{X}} = \mathbb{E}[\vec{X}\vec{X}^H] = \begin{pmatrix} \mathbb{E}[X_1 X_1^*] & \mathbb{E}[X_1 X_2^*] & \dots & \mathbb{E}[X_1 X_n^*] \\ \mathbb{E}[X_2 X_1^*] & \mathbb{E}[X_2 X_2^*] & \dots & \mathbb{E}[X_2 X_n^*] \\ \vdots & \vdots & \ddots & \vdots \\ \mathbb{E}[X_n X_1^*] & \mathbb{E}[X_n X_2^*] & \dots & \mathbb{E}[X_n X_n^*] \end{pmatrix} = (\mathbb{E}[X_i X_j])_{i,j}$$

显然, 相关矩阵是**共轭对称的**, 并且是**正定的**。

若将 $\vec{X}$ 的元素下标 n 视作时间, 则 $\vec{X}$ 可视为随机过程 $X(n)$ 的一个**样本向量 (sample vector)**, 其相关矩阵为该随机过程在这些时刻的相关函数值, 即

$$\mathbf{R}_{\vec{X}} = (R_X(i, j))_{i,j}$$

■ 去相关 (decorrelation)

考虑线性变换 $\vec{Y} = \mathbf{A}\vec{X}$, 其中 $\mathbf{A}$ 为方阵。我们希望找到使得 $\vec{Y}$ 的各分量**不相关**, 即 $\mathbb{E}[Y_i Y_j^*] = 0, \forall i \neq j$, 或

$$\mathbf{R}_{\vec{Y}} = \mathbb{E}[\vec{Y}\vec{Y}^H] = \mathbb{E}[\mathbf{A}\vec{X}\vec{X}^H\mathbf{A}^H] = \mathbf{A}\mathbf{R}_{\vec{X}}\mathbf{A}^H = \mathbf{A}_{\vec{Y}}$$

其中 $\mathbf{A}_{\vec{Y}}$ 是对角阵。

因 $\mathbf{R}_{\vec{X}}$ 是正定的, 故其**特征值均非负**, 且可以做**特征值分解 (EVD)**

$$\mathbf{R}_{\vec{X}} = \mathbf{Q}\mathbf{A}_{\vec{X}}\mathbf{Q}^H$$

其中 $\mathbf{Q}$ 是酉矩阵, $\mathbf{A}_{\vec{X}} = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_n)$, $\lambda_i \geq 0$ 。取 $\mathbf{A} = \mathbf{Q}^H$, 即可保证 $\mathbf{R}_{\vec{Y}} = \mathbf{A}_{\vec{X}}$ 。

Thm. 去相关变换

对随机变量 $\vec{X}$, 取 $\mathbf{R}_{\vec{X}}$ 的**特征值分解** $\mathbf{R}_{\vec{X}} = \mathbf{Q}\mathbf{A}_{\vec{X}}\mathbf{Q}^H$, 则线性变换

$$\vec{Y} = \mathbf{Q}^H\vec{X}$$

各分量**不相关**, 且 $\mathbf{R}_{\vec{Y}} = \mathbf{A}_{\vec{X}}$, 这个过程称为**去相关 (decorrelation)** 或**白化 (whitening)**。

■ 主成分分析 (PCA)

考虑 $\vec{X}$ 沿某个方向 $\vec{a}$ 的**投影**

$$\text{proj}_{\vec{a}}\vec{X} = \vec{a}(\vec{a}^T\vec{a})^{-1}\vec{a}^T\vec{X}$$

我们希望找到 $\vec{a}$ 使得这个投影「最大」, 即

$$\vec{a} = \arg \max_{\vec{a}} \mathbb{E} \left[\left\| \text{proj}_{\vec{a}}\vec{X} \right\|^2 \right] = \arg \max_{\vec{a}} \mathbb{E} \left[\frac{(\vec{a}^T\vec{X})^2}{\vec{a}^T\vec{a}} \right] = \arg \max_{\vec{a}} \vec{a}^T \mathbf{R}_{\vec{X}} \vec{a}$$

引入 Lagrange 乘子 λ , 构造 Lagrange 函数

$$\mathcal{L}(\vec{a}, \lambda) = \vec{a}^T \mathbf{R}_{\vec{X}} \vec{a} - \lambda (\vec{a}^T \vec{a} - 1)$$

对 $\vec{a}$ 求梯度并令其为零, 有

$$\nabla_{\vec{a}} \mathcal{L}(\vec{a}, \lambda) = 2\mathbf{R}_{\vec{X}}\vec{a} - 2\lambda\vec{a} = 0 \implies \mathbf{R}_{\vec{X}}\vec{a} = \lambda\vec{a}$$

因此, $\vec{a}$ 必须是 $\mathbf{R}_{\vec{X}}$ 的**特征向量 (eigenvector)**, λ 是对应的**特征值 (eigenvalue)**。而

$$\vec{a}^T \mathbf{R}_{\vec{X}} \vec{a} = \lambda \vec{a}^T \vec{a} = \lambda$$

因此应取最大的特征值对应的特征向量。

■ 双正交展开 (bi-orthogonal expansion)

► 随机变量列的双正交展开

在**去相关 (decorrelation)** 中, 我们已经知道可以通过线性变换将随机变量列 $\vec{X}$ 变为不相关的随机变量列 $\vec{Y} = \mathbf{Q}^H\vec{X}$, 其中 $\mathbf{Q}$ 是 $\mathbf{R}_{\vec{X}}$ 的特征向量矩阵。

考虑逆变换

$$\vec{X} = \mathbf{Q}\vec{Y} = \sum_{i=1}^n Y_i \vec{q}_i$$

其中 $\vec{q}_i$ 是 $\mathbf{Q}$ 的第 i 列, 即 $\mathbf{R}_{\vec{X}}$ 的第 i 个特征向量。显然,

- $\langle Y_i, Y_j \rangle = \mathbb{E}[Y_i Y_j^*] = 0, \forall i \neq j$, 即 $\vec{Y}$ 的各分量**正交**;
- $\langle \vec{q}_i, \vec{q}_j \rangle = \vec{q}_i^H \vec{q}_j = 0, \forall i \neq j$, 即 $\mathbf{Q}$ 的各列**正交**。

因此, 上面的展开称为**双正交展开 (bi-orthogonal expansion)**。

► 随机过程的双正交展开

考虑宽平稳随机过程 $X(t)$ ，我们希望找到一组函数 $\{\phi_n(t)\}$ 和一组随机变量 $\{\alpha_n\}$ ，使得

$$X(t) = \sum_{k=-\infty}^{+\infty} \alpha_k \phi_k(t)$$

且 $\{\phi_n(t)\}$ 和 $\{\alpha_n\}$ 分别**正交**，即

$$\begin{cases} \langle \phi_i, \phi_j \rangle = \int_{-\infty}^{+\infty} \phi_i(t) \phi_j^*(t) dt = \delta_{ij}, \\ \langle \alpha_i, \alpha_j \rangle = \mathbb{E}[\alpha_i \alpha_j^*] = \lambda_i \delta_{ij} \end{cases}$$

其中 $\lambda_i \geq 0$ 。

注意到 $\mathbf{R}_{\tilde{\mathbf{X}}}$ 的特征向量 $\{\tilde{\mathbf{q}}_i\}$ 是**正交归一化**的，因此可取 $\phi_i(t) = q_i(t)$ ，其中 $q_i(t)$ 是 $\tilde{\mathbf{q}}_i$ 的插值函数，即有

$$\mathbf{R}_{\tilde{\mathbf{X}}} \tilde{\mathbf{q}}_i = \left(\sum_{j=1}^n R_X(k, j) \phi_j(j) \right)_k = \lambda_i \tilde{\mathbf{q}}_i = (\lambda_i \phi_i(k))_k$$

取 $n \rightarrow \infty$ ，则可以猜想有

$$\int_{-\infty}^{+\infty} R_X(t, s) \phi_i(s) ds = \lambda_i \phi_i(t)$$

随机过程的平稳性

二阶矩随机过程

Def. 随机过程

随机过程 (stochastic process) 是一组随机变量的集合 $\{X(t) \mid t \in T\}$ ，其中 $T \subset \mathbb{R}$ 通常是时间参数集。
一个随机过程可视为同时依赖于**样本空间 Ω 中的样本点**和**时间 t** 的二元函数，即

$$X(\omega, t) : \Omega \times T \rightarrow \mathbb{R}$$

若随机过程 $X(t)$ 在每个时刻 t 的二阶矩存在，即 $\mathbb{E}[|X(t)|^2] < +\infty$ ，则称 $X(t)$ 为**二阶矩随机过程 (second-order moment stochastic process)**。二阶矩过程的均值和方差都存在，是电子技术与通信领域中最常见的随机过程。^[1]

随机过程的相关性

我们考察随机过程 $X(t)$ 在任意两个时刻 t_1 和 t_2 的统计关系。类比于**随机变量的相关**，定义

Def. 相关函数

对于**随机过程 $X(t)$** ，任取两个时刻 t_1 和 t_2 ，则 $X(t_1)$ 、 $X(t_2)$ 是两个随机变量，其**相关**定义为 $X(t)$ 的**相关函数 (correlation function)**，即

$$R_X(t_1, t_2) = \mathbb{E} \left[X(t_1) \overline{X(t_2)} \right]$$

显然，

- 同一时点的相关函数**非负**，即

$$R_X(t, t) = \mathbb{E}[|X(t)|^2] \geq 0$$

- 相关函数是**对称**的，即

$$R_X(t, s) = \overline{R_X(s, t)}$$

类似可以定义实随机过程的**协方差函数 (covariance function)**

$$C_X(t_1, t_2) = \mathbb{E} \left[(X(t_1) - \mathbb{E}[X(t_1)]) \overline{(X(t_2) - \mathbb{E}[X(t_2)])} \right]$$

其与相关函数的关系为

$$C_X(t_1, t_2) = R_X(t_1, t_2) - \mathbb{E}[X(t_1)] \overline{\mathbb{E}[X(t_2)]}$$

Def. 函数的正定性

我们称一个函数 $f(t)$ 是**正定 (positive definite)** 的，若对于任意整数 n 和任意实数 $t_1, t_2, \dots, t_n$ ，矩阵 $(f(t_i - t_j))_{i,j}$ 是正定的。

我们考虑随机过程 $X(t)$ 的有限维向量 $\tilde{\mathbf{X}} = (X(t_1), X(t_2), \dots, X(t_n))^T$ ，则

$$\mathbf{R} = \mathbb{E}[\tilde{\mathbf{X}} \cdot \tilde{\mathbf{X}}^H] = \left(\mathbb{E}[X(t_i) \overline{X(t_j)}] \right)_{i,j} = (R_X(t_i, t_j))_{i,j}$$

而 $\forall \tilde{\mathbf{x}} \in \mathbb{C}^n$ ，

$$\tilde{\mathbf{x}}^H \mathbf{R} \tilde{\mathbf{x}} = \mathbb{E} \left[\left(\tilde{\mathbf{x}}^H \tilde{\mathbf{X}} \right) \overline{\left(\tilde{\mathbf{x}}^H \tilde{\mathbf{X}} \right)} \right] = \mathbb{E} \left[\left| \tilde{\mathbf{x}}^H \tilde{\mathbf{X}} \right|^2 \right] \geq 0$$

因此 $\mathbf{R}$ 是正定的。

Thm. 相关函数的正定性

任意二阶矩随机过程 $X(t)$ 的**相关函数 $R_X(s, t)$** 是**正定**的。

正定性是相关函数的一种特征性质。如果一个二元函数具有正定性，则可以构造一个随机过程，使得该函数为其相关函数。

随机过程的平稳性

平稳性 (stationarity) 描述随机过程在时间平移前后的统计特性变化。若随机过程的任意有限维分布在时间平移后不变，即

$F_{X(t_1+\tau), \dots, X(t_n+\tau)} = F_{X(t_1), \dots, X(t_n)}$ ，则称该随机过程为**严平稳 (strict-sense stationary)** 随机过程，其各种性质都与绝对时间无关。

严平稳过程要求太高，信号缺少「发挥空间」。下面给出一个**假定**，研究符合下面性质的随机过程：

Def. 宽平稳随机过程

若随机过程 $X(t)$ 满足对于任意 T ，

- $\mathbb{E}[X(t+T)] = \mathbb{E}[X(t)]$ ，即**均值与时间无关**；
- $R_X(t_1+T, t_2+T) = R_X(t_1, t_2)$ ，即**相关函数只与时间差 $t_2 - t_1$ 有关**，

则称 $X(t)$ 为**宽平稳 (wide-sense stationary, WSS)** 随机过程。

对宽平稳随机过程 $X(t)$ ，相关函数 $R_X(s, t)$ 可简写为 $R_X(s - t)_0$ 。

宽平稳随机过程的性质

对宽平稳随机过程 $X(t)$ ，其相关函数有以下性质：

- 相关函数**共轭对称**， $R_X(\tau) = \overline{R_X(-\tau)}$ ；
- $|R_X(\tau)| \leq R_X(0)$ ，且 $R_X(0) = \mathbb{E}[|X(t)|^2] \geq \mathbb{E}[X(t)]^2$ ；
- $R_X(\tau)$ 是一元正定函数。

Thm. 宽平稳随机过程的周期性

对于宽平稳随机过程 $X(t)$ ，若存在 $T \neq 0$ 使得 $R_X(0) = R_X(T)$ ，则 $R_X(t)$ 以 T 为**周期**，即

$$\exists T \neq 0, \quad R_X(0) = R_X(T) \implies \forall \tau, \quad R_X(\tau) = R_X(\tau + T)$$

随机过程的均方微积分

《概率论与随机过程 (1)》曾介绍过随机变量列的**几乎处处收敛 $X_n \xrightarrow{a.c.} X$** 、**依概率收敛 $X_n \xrightarrow{p} X$** 、**依分布收敛 $X_n \xrightarrow{d} X$** 等概念。对于二阶矩随机过程 $X(t)$ ，常使用其在时间 t 上的**均方收敛 (mean-square convergence)**。

Def. 随机变量列均方收敛的极限

设随机变量列 $\{X_n\}$ 和随机变量 X 都有有限二阶矩, 若 $\forall \varepsilon > 0, \exists N \in \mathbb{N}$, 使得当 $n > N$ 时

$$\sqrt{\mathbb{E}[|X_n - X|^2]} < \varepsilon$$

也即 $\lim_{n \rightarrow \infty} \sqrt{\mathbb{E}[|X_n - X|^2]} = 0$, 则称 $\{X_n\}$ 均方收敛于 X , 记为

$X_n \xrightarrow{\text{m.s.}} X$, 或记为 $\text{l.i.m}_{n \rightarrow \infty} X_n = X$, 其中 **l.i.m** 表示均方极限 (limit in mean-square)。

在时间参数集 T 连续的情况下, 类似可以用 ε - δ 语言定义任意时间 t_0 处的 **l.i.m** $X(t) = X$, 进而可以定义其均方连续、均方可导、均方可积等性质。

均方连续

如果二阶矩随机过程 $X(t)$ 在 t_0 处满足

$$\lim_{t \rightarrow t_0} \sqrt{\mathbb{E}[|X(t) - X(t_0)|^2]} = 0$$

即 **l.i.m** $X(t) = X(t_0)$, 则称 $X(t)$ 在 t_0 处均方连续 (mean-square continuous)。

如果 $X(t)$ 在时间参数集 T 的每个点均均方连续, 则称 $X(t)$ 在 T 上均方连续。

Thm. 均方连续的充分必要条件

对在开区间 $T \subseteq \mathbb{R}$ 上的二阶矩随机过程 $X(t)$, 以下命题等价:

- $X(t)$ 在 T 上均方连续;
- $R_X(t_1, t_2)$ 在 $T \times T$ 上连续;
- $\forall t \in T, R_X(t_1, t_2)$ 在 (t, t) 处连续。

特别地, 对宽平稳随机过程 $X(t)$, 其均方连续的充分必要条件为 $R_X(\tau)$ 在 $\tau = 0$ 处连续。

均方可导、均方可积

若二阶矩随机过程 $X(t)$ 在 t_0 处满足

$$\text{l.i.m}_{b \rightarrow 0} \frac{X(t_0 + b) - X(t_0)}{b} = Y(t_0)$$

则称 $X(t)$ 在 t_0 处均方可导 (mean-square differentiable), $Y(t_0)$ 为 $X(t)$ 在 t_0 处的均方导数 (mean-square derivative), 记为 $X'(t_0)$ 、 $\left. \frac{dX(t)}{dt} \right|_{t=t_0}$ 或 $\dot{X}(t_0)$ 。如果 $X(t)$ 在时间参数集 T 的每个点均均方可导, 则称 $X(t)$ 在 T 上均方可导。

一般地, 确认可导性前具体导数值未知, 用这一定义判断均方可导性较为困难。下面给出一个更易用的判定条件。

Thm. 均方可导的充分必要条件

随机过程 $X(t)$ 在 t_0 处均方可导的充分必要条件为 $R_X(t_1, t_2)$ 在 (t_0, t_0) 处二阶广义可微, 即存在极限

$$\lim_{\substack{b \rightarrow 0 \\ k \rightarrow 0}} \frac{R_X(t_0 + b, t_0 + k) - R_X(t_0 + b, t_0) - R_X(t_0, t_0 + k) + R_X(t_0, t_0)}{bk}$$

由此得到一个更方便的充分条件: 若 $\frac{\partial^2}{\partial t_1 \partial t_2} R_X(t_1, t_2)$ 在 (t_0, t_0) 的邻域内存在且在 (t_0, t_0) 处连续, 则上述极限存在, $X(t)$ 在 t_0 处均方可导。

对于宽平稳随机过程 $X(t)$, 其均方可导的充分必要条件为 $R_X(\tau)$ 在 $\tau = 0$ 处二阶广义可微, 或者 $\frac{d^2}{d\tau^2} R_X(\tau)$ 在 $\tau = 0$ 处存在、有限。

对应地, 若二阶矩随机过程 $X(t)$ 及确定性函数 $b(t)$ 满足

$\int_a^b \int_a^b R_X(s, t) b(s) b(t) ds dt$ 存在, 则 $X(t) b(t)$ 在 $[a, b]$ 上均方可积 (mean-square integrable), 且其均方积分定义为 Riemann 和的均方极限

$$\int_a^b X(t) b(t) dt = \text{l.i.m}_{\max\{\Delta t_i\} \rightarrow 0} \sum_{i=1}^n X(t_i^*) b(t_i^*) \Delta t_i$$

均值遍历

均值遍历性 (mean ergodicity) 描述随机过程的时间平均 $\langle X(t) \rangle$ 和统计平均 $\mathbb{E}[X(t)]$ 之间的关系。若对于随机过程 $X(t)$, 其时间平均以某种方式收敛于统计平均, 则称 $X(t)$ 为均值遍历的随机过程。

对于宽平稳随机过程 $X(t)$, 通常以均方收敛考察均值遍历性, 即

$$\text{l.i.m}_{T \rightarrow \infty} \frac{1}{2T} \int_{-T}^T X(t) dt = \mathbb{E}[X(t)] = m_X$$

注意此时左侧的积分不是均方积分, 而是沿选中的样本轨道做普通的 Riemann 积分, 在 $T \rightarrow \infty$ 时才合并样本轨道为均方极限。

对于实数宽平稳过程, 以下命题等价:

- $X(t)$ 是均值遍历的;
- $\lim_{T \rightarrow \infty} \frac{1}{T} \int_{-T}^T \left(1 - \frac{|\tau|}{T}\right) C_X(\tau) d\tau = 0$;
- $\lim_{T \rightarrow \infty} \frac{1}{T} \int_{-T}^T C_X(\tau) d\tau = 0$ 。

并且, 有如下两个推论:

- 若 $C_X(\tau)$ 可积, 即 $\int_0^{+\infty} C_X(\tau) d\tau < +\infty$, 则 $X(t)$ 是均值遍历的;
- 若 $C_X(0)$ 有限, 而足够远处 $\lim_{\tau \rightarrow \infty} C_X(\tau) = 0$, 则 $X(t)$ 是均值遍历的。

宽平稳随机过程的谱分析

相关函数的谱表示

我们已经知道相关函数的正定性, 下面考虑如何对给定的正定函数 $R(\tau)$ 构造一个宽平稳随机过程 $X(t)$, 使得 $R(\tau)$ 成为其相关函数。

Thm. 正定函数与 Fourier 变换的关系

函数 $f(t)$ 是正定的, 当且仅当其 Fourier 变换 $\hat{f}(\omega)$ 非负。

Sufficiency:

对 $e^{j\omega t}$ ，显然有

$$(e^{j\omega(t_i-t_j)})_{i,j} = \vec{g}\vec{g}^H, \quad \vec{g} = (e^{j\omega t_1}, e^{j\omega t_2}, \dots, e^{j\omega t_n})^T$$

因此 $e^{j\omega t}$ 是正定的。进而，对任意实函数 $\hat{f}(\omega) \geq 0$ ，有 Fourier 逆变换函数

$$f(t) = \frac{1}{2\pi} \int_{-\infty}^{+\infty} \hat{f}(\omega) e^{j\omega t} d\omega$$

是正定的。

Necessity:

若 $f(t)$ 是正定的，则对任意整数 n 和任意实数 $t_1, t_2, \dots, t_n$ ，矩阵 $(f(t_i - t_j))_{i,j}$ 也是正定的。特别地，取定 $\vec{x} = (e^{-j\omega t_1}, e^{-j\omega t_2}, \dots, e^{-j\omega t_n})$ ，则正定性要求

$$\vec{x}^H (f(t_i - t_j))_{i,j} \vec{x} = \sum_{i=1}^n \sum_{j=1}^n f(t_i - t_j) e^{-j\omega(t_i - t_j)} \geq 0$$

进而转换为积分形式，有

$$\frac{1}{T} \int_{-T}^T \int_{-T}^T f(t-s) e^{-j\omega(t-s)} dt ds \geq 0$$

做变量替换 $u = t - s$ ， $v = t + s$ ，Jacobian 行列式为 $\left| \frac{D(t,s)}{D(u,v)} \right| = \frac{1}{2}$ ，积分区域变为 $|u| \leq 2T$ ， $|v| \leq 2T - |u|$ 的菱形，因此

$$\begin{aligned} \text{LHS} &= \frac{1}{T} \int_{-2T}^{2T} \int_{|v|=|u|}^{2T-|u|} f(u) e^{-j\omega u} \cdot \frac{1}{2} dv du \\ &= \frac{1}{2T} \int_{-2T}^{2T} f(u) e^{-j\omega u} (4T - 2|u|) du = \int_{-2T}^{2T} \left(2 - \frac{|u|}{T}\right) f(u) e^{-j\omega u} du \\ &\xrightarrow{T \rightarrow +\infty} \int_{-\infty}^{+\infty} f(u) e^{-j\omega u} du \geq 0 \end{aligned}$$

Lebesgue dominated

因此，正定函数 $f(t)$ 的 Fourier 变换

$$\hat{f}(\omega) = \int_{-\infty}^{+\infty} f(t) e^{-j\omega t} dt \geq 0$$

非负。

上述定理启发我们，相关函数的 Fourier 变换非负，而相关函数本身是随机过程的二阶矩，因此这个 Fourier 变换应当与随机过程的**功率—频率**关系有关。下面仿照上述证明过程，定义随机过程的**功率谱**，这样即可认为构造出了一个以给定正定函数 $R(\tau)$ 为相关函数的宽平稳随机过程。

► 随机过程的功率谱

对于一般的随机过程 $X(t)$ ，不能保证 $\int |X(t)| dt < \infty$ ，因此不能直接进行 Fourier 变换。

随机过程的**功率谱 (power spectrum)** 定义为随机过程 $X_T(t)$ 的**截断** Fourier 变换 (STFT) 的模平方期望的极限。

Def. 随机过程的功率谱密度

对于随机过程 $X(t)$ ，定义其**功率谱密度 (power spectrum density)** 为

$$S_X(\omega) = \lim_{T \rightarrow +\infty} \frac{1}{2T} \mathbb{E} \left[\left| \int_{-T}^T X(t) e^{-j\omega t} dt \right|^2 \right]$$

显然， $S_X(\omega) \geq 0$ ；展开后，有

$$\begin{aligned} S_X(\omega) &= \lim_{T \rightarrow +\infty} \frac{1}{2T} \mathbb{E} \left[\left(\int_{-T}^T X(t) e^{-j\omega t} dt \right) \overline{\left(\int_{-T}^T X(s) e^{j\omega s} ds \right)} \right] \\ &= \lim_{T \rightarrow +\infty} \frac{1}{2T} \int_{-T}^T \int_{-T}^T \mathbb{E}[X(t) X^*(s)] e^{-j\omega(t-s)} dt ds \\ &= \int_{-\infty}^{+\infty} R_X(u) e^{-j\omega u} du = \mathcal{F}\{R_X(t)\} \end{aligned}$$

其中第 3 个等号与上面「正定函数与 Fourier 变换的关系」的证明类似，用到 $R_X(\tau) = \mathbb{E}[X(t+\tau)X(t)]$ ，因此一般需要 $X(t)$ 为**宽平稳随机过程**。

Thm. Wiener-Khinchin 关系

宽平稳随机过程 $X(t)$ 的**功率谱密度** $S_X(\omega)$ 是其相关函数 $R_X(t)$ 的**Fourier 变换**，即

$$S_X(\omega) = \mathcal{F}\{R_X(t)\} = \int_{-\infty}^{+\infty} R_X(t) e^{-j\omega t} dt$$

反之，

$$R_X(t) = \mathcal{F}^{-1}\{S_X(\omega)\} = \frac{1}{2\pi} \int_{-\infty}^{+\infty} S_X(\omega) e^{j\omega t} d\omega$$

常见**相关函数** $R(\tau)$ 与对应**功率谱密度** $S(\omega)$ 有

相关函数 $R(\tau)$	功率谱密度 $S(\omega)$	注
$R(\tau) = e^{-\alpha \tau }, \quad \alpha > 0$	$S(\omega) = \frac{2\alpha}{\alpha^2 + \omega^2}$	
$R(\tau) = \delta(\tau)$	$S(\omega) = 1$	理想白噪声
$R(\tau) = \cos \omega_0 \tau$	$S(\omega) = \pi(\delta(\omega - \omega_0) + \delta(\omega + \omega_0))$	随机相位
$R(\tau) = \frac{\sin \omega_0 \tau}{\omega_0 \tau}$	$S(\omega) = \begin{cases} \frac{\pi}{\omega_0}, & \omega \leq \omega_0 \\ 0, & \omega > \omega_0 \end{cases}$	理想低通
$R(\tau) = \begin{cases} 1 - \frac{2 \tau }{T}, & \tau \leq \frac{T}{2} \\ 0, & \tau > \frac{T}{2} \end{cases}$	$S(\omega) = \frac{8 \sin^2\left(\frac{\omega T}{4}\right)}{\omega^2 T}$	
$R(\tau) = e^{-\alpha \tau } \cos \omega_0 \tau, \quad \alpha > 0$	$S(\omega) = \frac{\alpha}{\alpha^2 + (\omega - \omega_0)^2} + \frac{\alpha}{\alpha^2 + (\omega + \omega_0)^2}$	
$R(\tau) = e^{-\alpha\tau^2}, \quad \alpha > 0$	$S(\omega) = \sqrt{\frac{\pi}{\alpha}} e^{-\frac{\omega^2}{4\alpha}}$	
$R(\tau) = e^{-\alpha\tau^2} \cos \beta \tau, \quad \alpha > 0$	$S(\omega) = \frac{1}{2} \sqrt{\frac{\pi}{\alpha}} \left(e^{-\frac{(\omega-\beta)^2}{4\alpha}} + e^{-\frac{(\omega+\beta)^2}{4\alpha}} \right)$	
$R(\tau) = \frac{2 \sin\left(\frac{\Delta\omega}{2}\tau\right)}{\pi\tau} \cos(\omega_0\tau)$	$S(\omega) = \begin{cases} 1, & \omega_0 - \frac{\Delta\omega}{2} \leq \omega \leq \omega_0 + \frac{\Delta\omega}{2} \\ 0, & \text{otherwise} \end{cases}$	理想带通

对于离散时间的宽平稳随机过程 $X[n]$ ，Wiener-Khinchin 关系类似，只是变为**DTFT 关系**，即

$$S_X(e^{j\omega}) = \sum_{n=-\infty}^{+\infty} R_X[n] e^{-j\omega n}, \quad R_X[n] = \frac{1}{2\pi} \int_{-\pi}^{\pi} S_X(e^{j\omega}) e^{j\omega n} d\omega$$

尽管一只只对**宽平稳**随机过程定义功率谱，但实则只需要满足**相关函数的平稳性**即可有 Wiener-Khinchin 关系。

Note 功率谱的物理意义

功率谱描述随机过程在不同频率上的功率分布情况。对功率谱 $S_X(\omega)$ 在全频域积分，有

$$\int_{-\infty}^{+\infty} S_X(\omega) d\omega = 2\pi R_X(0) = 2\pi \mathbb{E}[|X(t)|^2]$$

此即随机过程 $X(t)$ 的功率。

对于**实值宽平稳**随机过程 $X(t)$ ，相关函数 $R_X(\tau) = \mathbb{E}[X(t)X(t+\tau)]$ 即为**实值偶函数**，因此

$$\begin{aligned} S_X(\omega) &= \int_{-\infty}^{+\infty} R_X(t) e^{-j\omega t} dt \\ &= \int_{-\infty}^{+\infty} R_X(t) \cos(\omega t) dt - j \int_{-\infty}^{+\infty} \underbrace{R_X(t) \sin(\omega t)}_{\text{odd}} dt \\ &= \int_{-\infty}^{+\infty} R_X(t) \cos(\omega t) dt = S_X(-\omega) \end{aligned}$$

功率谱 $S_X(\omega)$ 也为**实值偶函数**。

► 谱分布函数

功率谱密度 $S_X(\omega)$ 是针对平稳过程的相关函数 $R_X(\tau)$ 做 Fourier 变换得到的。但并非所有随机过程都存在密度函数，更一般的描述是**谱分布函数 (spectral distribution function)** $F_X(\omega)$ 。

Bochner-Khinchin 定理指出，任意的连续一元正定函数 $R(\tau)$ 都可以表示为某个**非减**函数 $F(\omega)$ 的 Fourier-Stieltjes 变换

$$R(\tau) = \int_{-\infty}^{+\infty} e^{j\omega\tau} dF(\omega)$$

其中 $F(\omega)$ 即为**谱分布**函数；若进一步满足 $\int_{-\infty}^{+\infty} |R(\tau)| d\tau < \infty$ ，则 $F(\omega)$ 可导且导数即为功率谱密度 $S(\omega) = \frac{dF(\omega)}{d\omega}$ 。

■ + 随机过程的谱表示

考虑如下的两个空间

$$\begin{aligned} X(t) &\longleftrightarrow \exp(j\omega t) \\ \text{span}\{X(t)\} &\longleftrightarrow L^2(\mathbb{R}, dF_X(\omega)) \end{aligned}$$

其中：

- $\text{span}\{X(t)\} = L^2(\Omega, \mathcal{F}, P)$ 是定义在概率空间 $(\Omega, \mathcal{F}, P)$ 上的二次可积**随机变量**空间，其上 $X(t_1)$ 与 $X(t_2)$ 间距离**以均方意义**定义为

$$d(X(t_1), X(t_2)) = \sqrt{\mathbb{E}[|X(t_1) - X(t_2)|^2]} = \sqrt{2(R_X(0) - R_X(t_1 - t_2))}$$

- $L^2(\mathbb{R}, dF_X(\omega))$ 是定义在实数集 $\mathbb{R}$ 上、以复指数函数 $\exp(j\omega t)$ 为基底的二次可积**函数**空间，其上 $F(\omega)$ 与 $G(\omega)$ 间距离**以 $dF_X(\omega)$ 定义**为

$$\begin{aligned} d^2(F, G) &= \int_{-\infty}^{+\infty} |F(\omega) - G(\omega)|^2 dF_X(\omega) \\ &= \frac{1}{2\pi} \int_{-\infty}^{+\infty} S_X(\omega) |F(\omega) - G(\omega)|^2 d\omega \end{aligned}$$

下面证明，这两个空间构成**等距同构 (isometric isomorphism)**，即

$$\mathbb{E}[|X(t_1) - X(t_2)|^2] = \frac{1}{2\pi} \int_{-\infty}^{+\infty} S_X(\omega) |\exp(j\omega t_1) - \exp(j\omega t_2)|^2 d\omega$$

利用欧拉公式 $|e^{j\theta_1} - e^{j\theta_2}|^2 = 2 - 2\cos(\theta_1 - \theta_2)$ ，得到

$$\begin{aligned} \text{RHS} &= \frac{1}{2\pi} \int_{-\infty}^{+\infty} |e^{j\omega t_1} - e^{j\omega t_2}|^2 S_X(\omega) d\omega \\ &= \frac{1}{2\pi} \int_{-\infty}^{+\infty} (2 - 2\cos(\omega(t_1 - t_2))) S_X(\omega) d\omega \\ &= 2 \cdot \underbrace{\frac{1}{2\pi} \int_{-\infty}^{+\infty} S_X(\omega) d\omega}_{R_X(0)} - 2 \cdot \underbrace{\frac{1}{2\pi} \int_{-\infty}^{+\infty} \cos(\omega(t_1 - t_2)) S_X(\omega) d\omega}_{R_X(t_1 - t_2)} \\ &= 2R_X(0) - 2R_X(t_1 - t_2) = \mathbb{E}[|X(t_1) - X(t_2)|^2] = \text{LHS} \end{aligned}$$

因此，随机过程 $X(t)$ 可以表示为

$$X(t) = \frac{1}{2\pi} \int_{-\infty}^{+\infty} e^{j\omega t} dZ(\omega)$$

其中随机增量过程 $Z(\omega)$ 称为 $X(t)$ 的**谱过程**，满足

- $\mathbb{E}[dZ(\omega)] = 0$ ；
- $\mathbb{E}[|dZ(\omega)|^2] = S_X(\omega) d\omega$ ；
- 对于 $\omega_1 \neq \omega_2$ ， $dZ(\omega_1)$ 与 $dZ(\omega_2)$ **不相关**。

■ LTI 系统对宽平稳随机过程的作用

以**宽平稳**随机过程 $X(t)$ 作为**线性时不变 (LTI) 系统** $b(t)$ 的输入，输出为随机过程 $Y(t)$ ，则

$$Y(t) = X(t) * b(t) = \int_{-\infty}^{+\infty} X(\tau) b(t - \tau) d\tau$$

因此

$$\begin{aligned} R_Y(t, s) &= \mathbb{E}[Y(t) \overline{Y(s)}] \\ &= \mathbb{E}\left[\left(\int_{-\infty}^{+\infty} X(\tau) b(t - \tau) d\tau\right) \overline{\left(\int_{-\infty}^{+\infty} X(\sigma) b(s - \sigma) d\sigma\right)}\right] \\ &= \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} b(t - \tau) \overline{b(s - \sigma)} \mathbb{E}[X(\tau) \overline{X(\sigma)}] d\tau d\sigma \\ &= \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} b(t - \tau) \overline{b(s - \sigma)} R_X(\tau - \sigma) d\tau d\sigma \end{aligned}$$

记 $\bar{b}(t) = \overline{b(-t)}$ ，则

$$R_Y(t, s) = (R_X * b * \bar{b})(t - s)$$

因此， $Y(t)$ **也是宽平稳随机过程**，其**谱**函数为

$$S_Y(\omega) = \mathcal{F}\{R_X * b * \bar{b}\} = S_X(\omega) \cdot H(j\omega) \cdot \bar{H}(j\omega)$$

而

$$\bar{H}(j\omega) = \int_{-\infty}^{+\infty} \overline{b(-t)} e^{-j\omega t} dt = \int_{-\infty}^{+\infty} \overline{b(u)} e^{j\omega u} du = \overline{H(j\omega)}$$

因此

$$S_Y(\omega) = S_X(\omega) \cdot H(j\omega) \cdot \overline{H(j\omega)} = \boxed{S_X(\omega) |H(j\omega)|^2}$$

其中 $H(\omega)$ 是系统 $b(t)$ 的**频率响应 (frequency response)**。

≡ **例 5-1**：滑动平均积分器对随机过程的作用

≡ **例 5-2**：白噪声通过 LTI 系统。

利用随机过程的谱分布函数，可以更直观地看到 LTI 系统对随机过程的作用。设随机过程 $X(t)$ 、 $Y(t)$ 的谱分布函数分别为 $F_X(\omega)$ 、 $F_Y(\omega)$ ，则

$$\begin{aligned} Y(t) &= \int_{-\infty}^{+\infty} b(t - \tau) X(\tau) d\tau = \int_{-\infty}^{+\infty} b(t - \tau) \int_{-\infty}^{+\infty} \exp(j\omega\tau) dF_X(\omega) d\tau \\ &= \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} \exp(j\omega\tau) b(t - \tau) d\tau dF_X(\omega) \\ &= \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} \exp(j\omega(t - \tau')) b(\tau') d(t - \tau') dF_X(\omega) \\ &= \int_{-\infty}^{+\infty} \underbrace{\left(\int_{-\infty}^{+\infty} \exp(-j\omega\tau') b(\tau') d\tau'\right)}_{H(\omega)} \exp(j\omega t) dF_X(\omega) \\ &= \int_{-\infty}^{+\infty} H(\omega) \exp(j\omega t) dF_X(\omega) \end{aligned}$$

对照 $Y(t) = \int_{-\infty}^{+\infty} \exp(j\omega t) dF_Y(\omega)$ ，可见

$$dF_Y(\omega) = H(\omega) dF_X(\omega)$$

即 LTI 系统**频率响应**直接作用于随机过程的**谱分布函数**。

■ 随机过程的互功率谱

对于两个**宽平稳随机过程** $X(t)$ 和 $Y(t)$ ，其互相关函数为

$$R_{XY}(\tau) = \mathbb{E}[X(t + \tau) \overline{Y(t)}], \quad R_{YX}(\tau) = \mathbb{E}[Y(t + \tau) \overline{X(t)}]$$

考虑 $X(t)$ 通过 LTI 系统 $H(\omega)$ 得到输出 $Y(t)$ ，做谱分解

$$\begin{aligned} X(t) &= \int_{-\infty}^{+\infty} e^{j\omega t} dF_X(\omega), \\ Y(t) &= \int_{-\infty}^{+\infty} e^{j\omega t} dF_Y(\omega) = \int_{-\infty}^{+\infty} e^{j\omega t} H(\omega) dF_X(\omega) \end{aligned}$$

得到

$$\begin{aligned} R_{XY}(\tau) &= \mathbb{E}[X(t + \tau) \overline{Y(t)}] \\ &= \mathbb{E}\left[\left(\int_{-\infty}^{+\infty} e^{j\omega_1(t + \tau)} dF_X(\omega_1)\right) \overline{\left(\int_{-\infty}^{+\infty} e^{-j\omega_2 t} H(\omega_2) dF_X(\omega_2)\right)}\right] \\ &= \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} e^{j\omega_1 \tau} \overline{H(\omega_2)} \mathbb{E}[dF_X(\omega_1) \overline{dF_X(\omega_2)}] \\ &= \frac{1}{2\pi} \int_{-\infty}^{+\infty} e^{j\omega \tau} \overline{H(\omega)} S_X(\omega) d\omega \end{aligned}$$

因此，类比功率谱密度的定义，我们期望有

$$R_{XY}(\tau) = \frac{1}{2\pi} \int_{-\infty}^{+\infty} \underbrace{\overline{H(\omega)} S_X(\omega)}_{S_{XY}(\omega)} e^{j\omega \tau} d\omega$$

⌘ Def. 随机过程的互功率谱密度

对于两个宽平稳随机过程 $X(t)$ 和 $Y(t)$ ，定义其**互功率谱密度 (cross power spectrum density)** 为

$$S_{XY}(\omega) = \mathcal{F}\{R_{XY}(\tau)\} = \int_{-\infty}^{+\infty} R_{XY}(\tau) e^{-j\omega\tau} d\tau$$

其中 $R_{XY}(\tau) = \mathbb{E}[X(t+\tau)\overline{Y(t)}]$ 为互相关函数。

于是

$$S_{XY}(\omega) = \overline{H(\omega)} S_X(\omega), \quad S_{YX}(\omega) = \overline{S_{XY}(\omega)} = H(\omega) S_X(\omega)$$

互功率谱不再描述能量（功率）分布，也就不再一定是实值函数；它描述的是**两个随机过程在不同频率上的相关性**。

循环平稳过程

■ 循环平稳过程的定义

我们已知**宽平稳过程** $X(t)$ 满足

$$\forall T \in \mathbb{R}, \quad \begin{cases} \mathbb{E}[X(t+T)] = \mathbb{E}[X(t)] \\ R_X(s+T, t+T) = R_X(s, t) \end{cases}$$

因此， $R_X(s, t)$ 只与时间差 $t-s$ 有关。

类似地，若有随机过程 $X(t)$ 满足

$$\exists T \neq 0, \quad \begin{cases} \mathbb{E}[X(t+T)] = \mathbb{E}[X(t)] \\ R_X(s+T, t+T) = R_X(s, t) \end{cases}$$

这个随机过程应该也有特殊的概率性质。

⌘ Def. 循环平稳过程

对随机过程 $X(t)$ ，如果存在 $T \neq 0$ ，使得

- $\mathbb{E}[X(t+T)] = \mathbb{E}[X(t)]$ ，即**均值具有周期性**，且
- $R_X(s+T, t+T) = R_X(s, t)$ ，即**相关函数具有周期性**，

则称 $X(t)$ 为**循环平稳 (cyclostationary)** 过程，或称为**周期平稳 (periodically stationary)** 过程。

循环平稳过程是典型的**非平稳随机过程**，但它的均值和相关函数都具有周期性，使得其分析相对简单。

■ 循环平稳与宽平稳的联系

设有周期为 T 的循环平稳过程 $X(t)$ ，我们考察其**移位过程**

$$Y(t) = X(t + \theta)$$

其中 $\theta \sim U(0, T)$ **独立** 于 $X(t)$ 。则 $Y(t)$ 的相关为

$$\begin{aligned} R_Y(t, s) &= \mathbb{E}[Y(t)Y(s)] = \mathbb{E}[X(t+\theta)X(s+\theta)] \\ &= \mathbb{E}_\theta[\mathbb{E}_{X|\theta}[X(t+\theta)X(s+\theta) | \theta]] \\ &= \mathbb{E}_\theta[R_X(t+\theta, s+\theta)] \\ &= \frac{1}{T} \int_0^T R_X(t+\theta, s+\theta) d\theta = \frac{1}{T} \int_s^{s+T} R_X(t-s+\theta', \theta') d\theta' \\ &= \frac{1}{T} \int_0^T R_X(t-s+\theta', \theta') d\theta' = R_X(t-s) \end{aligned}$$

可见，**移位过程 $Y(t)$ 是宽平稳过程**。

通过移位操作可以将循环平稳过程转化为宽平稳过程，从而利用宽平稳过程的分析方法研究循环平稳过程的性质。

≡ EG. 例题 > L5-3: 脉冲幅度调制

考察随机信号

$$X(t) = \sum_{k=-\infty}^{\infty} \alpha_k \phi(t - kT)$$

其中 $\{\alpha_k\}$ 是平稳的随机序列，满足

$$\mathbb{E}[\alpha_k] = 0, \quad \mathbb{E}[\alpha_k \alpha_{k+m}] = R_\alpha(m)$$

而 $\phi(t)$ 是一个给定的基带 (baseband) 脉冲，其自相关函数为

$$R_\phi(\tau) = \int_{-\infty}^{+\infty} \phi(t)\phi(t+\tau) dt$$

† Hilbert 变换

▀ Hilbert 变换的引入

考虑一个线性滤波器

$$H(\omega) = -j \operatorname{sgn}(\omega) = \begin{cases} -j, & \omega > 0, \\ 0, & \omega = 0, \\ j, & \omega < 0 \end{cases}$$

其时域冲激响应为

$$h(t) = \frac{1}{2\pi} \int_{-\infty}^{+\infty} H(\omega) e^{j\omega t} d\omega = \frac{1}{\pi t}$$

该滤波器称为 **Hilbert 变换 (Hilbert transform)**，记作 $\mathcal{H}_h\{\cdot\}$ 。

■ Hilbert 变换对复指数信号的作用

考虑输入信号为**复指数信号** $x(t) = e^{j\omega_0 t}$ ，则其频谱为

$$\hat{x}(\omega) = 2\pi \delta(\omega - \omega_0)$$

不妨假设 $\omega_0 > 0$ ，经过 Hilbert 变换后，输出频谱为

$$\hat{y}(\omega) = H(\omega) \hat{x}(\omega) = -j \operatorname{sgn}(\omega) \cdot 2\pi \delta(\omega - \omega_0) = -j \cdot 2\pi \delta(\omega - \omega_0)$$

因此时域输出信号为

$$y(t) = \mathcal{H}_h\{x(t)\} = -j e^{j\omega_0 t} = e^{j(\omega_0 t - \frac{\pi}{2})}$$

若输入信号为**负频率**成分 $x(t) = e^{-j\omega_0 t}$ ，则类似地可得输出信号为

$$y(t) = \mathcal{H}_h\{x(t)\} = j e^{-j\omega_0 t} = e^{-j(\omega_0 t - \frac{\pi}{2})}$$

即 Hilbert 变换将正频率成分的相位延迟了 $\frac{\pi}{2}$ 。

因此，

- 对余弦输入 $\cos(\omega_0 t) = \frac{1}{2}(e^{j\omega_0 t} + e^{-j\omega_0 t})$ ，Hilbert 变换的输出为

$$\mathcal{H}_h\{\cos(\omega_0 t)\} = \frac{1}{2}(-j e^{j\omega_0 t} + j e^{-j\omega_0 t}) = \sin(\omega_0 t)$$

- 对正弦输入 $\sin(\omega_0 t) = \frac{1}{2j}(e^{j\omega_0 t} - e^{-j\omega_0 t})$ ，Hilbert 变换的输出为

$$\mathcal{H}_h\{\sin(\omega_0 t)\} = \frac{1}{2j}(-j e^{j\omega_0 t} - j e^{-j\omega_0 t}) = -\cos(\omega_0 t)$$

即 Hilbert 变换将**余弦信号变为正弦信号**，将**正弦信号变为负余弦信号**，相当于将信号相位延迟 $\frac{\pi}{2}$ 。

■ Hilbert 变换对带限调制信号的作用

设输入信号 $x(t)$ 为**带限信号**，其频谱 $\hat{x}(\omega)$ 满足

$$\hat{x}(\omega) = 0, \quad |\omega| > \omega_c$$

其可乘以载波 $\cos(\omega_0 t)$ ($\omega_0 > \omega_c$) 进行调制，频谱迁移为

$\frac{1}{2}(\hat{x}(\omega - \omega_0) + \hat{x}(\omega + \omega_0))$ 。对该调制信号进行 Hilbert 变换，输出频谱为

$$H(\omega) \cdot \frac{1}{2}(\hat{x}(\omega - \omega_0) + \hat{x}(\omega + \omega_0)) = \frac{1}{2}(-\mathbb{J}\hat{x}(\omega - \omega_0) + \mathbb{J}\hat{x}(\omega + \omega_0))$$

因此时域输出信号为

$$\begin{aligned}\mathcal{H}_h\{x(t)\cos(\omega_0 t)\} &= \mathcal{F}^{-1}\left\{\frac{1}{2}(-\mathbb{J}\hat{x}(\omega - \omega_0) + \mathbb{J}\hat{x}(\omega + \omega_0))\right\} \\ &= \frac{1}{2}(-\mathbb{J}x(t)e^{\mathbb{J}\omega_0 t} + \mathbb{J}x(t)e^{-\mathbb{J}\omega_0 t}) \\ &= x(t) \cdot \frac{1}{2}(-\mathbb{J})\left(e^{\mathbb{J}\omega_0 t} - e^{-\mathbb{J}\omega_0 t}\right) = x(t)\sin(\omega_0 t)\end{aligned}$$

即 Hilbert 变换将调制信号 $x(t)\cos(\omega_0 t)$ 转换为 $x(t)\sin(\omega_0 t)$ ，相当于将载波信号相位延迟 $\frac{\pi}{2}$ 。

同理，对调制信号 $x(t)\sin(\omega_0 t)$ ，Hilbert 变换的输出为

$$\mathcal{H}_h\{x(t)\sin(\omega_0 t)\} = -x(t)\cos(\omega_0 t)$$

随机过程的 Hilbert 变换

设随机过程 $X(t)$ 有分解

$$X(t) = \int_{-\infty}^{\infty} e^{\mathbb{J}\omega t} dF_X(\omega)$$

其中 $F_X(\omega)$ 是随机过程 $X(t)$ 的**频率分量随机变量列 (frequency component random variable series)**。则 Hilbert 变换后的随机过程为

$$\tilde{X}(t) = \mathcal{H}_h\{X(t)\} = \int_{-\infty}^{\infty} e^{\mathbb{J}\omega t} \cdot (-\mathbb{J}\operatorname{sgn}(\omega)) dF_X(\omega)$$

Hilbert 变换对宽平稳随机过程的作用

设随机过程 $X(t)$ 是**随机过程的平稳性**，其均值为 $\mu_X = \mathbb{E}[X(t)]$ ，自相关函数为 $R_X(\tau) = \mathbb{E}[X(t)X(t+\tau)]$ 。则 Hilbert 变换后的随机过程 $\tilde{X}(t)$ 也是**宽平稳随机过程**，有

$$\begin{aligned}R_{\tilde{X}}(\tau) &= \mathbb{E}\left[\tilde{X}(t+\tau)\overline{\tilde{X}(t)}\right] \\ &= \mathbb{E}\left[\int_{-\infty}^{\infty} e^{\mathbb{J}\omega(t+\tau)}(-\mathbb{J}\operatorname{sgn}(\omega)) dF_X(\omega) \cdot \int_{-\infty}^{\infty} e^{-\mathbb{J}\omega' t}(\mathbb{J}\operatorname{sgn}(\omega')) dF_X(\omega')\right] \\ &= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} e^{\mathbb{J}\omega\tau + \mathbb{J}(\omega - \omega')t} \operatorname{sgn}(\omega) \operatorname{sgn}(\omega') \cdot \mathbb{E}\left[dF_X(\omega) dF_X(\omega')\right] \\ &= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} e^{\mathbb{J}\omega\tau + \mathbb{J}(\omega - \omega')t} \operatorname{sgn}(\omega) \operatorname{sgn}(\omega') \cdot \frac{1}{2\pi} \delta(\omega - \omega') S_X(\omega) d\omega d\omega' \\ &= \frac{1}{2\pi} \int_{-\infty}^{\infty} e^{\mathbb{J}\omega\tau} \operatorname{sgn}^2(\omega) S_X(\omega) d\omega = \frac{1}{2\pi} \int_{-\infty}^{\infty} e^{\mathbb{J}\omega\tau} S_X(\omega) d\omega = R_X(\tau)\end{aligned}$$

即 Hilbert 变换**不改变宽平稳随机过程的自相关函数**。

类似地，我们得到

$$\begin{aligned}R_{\tilde{X}\tilde{X}}(\tau) &= \mathbb{E}\left[\tilde{X}(t+\tau)\overline{\tilde{X}(t)}\right] = \frac{1}{2\pi} \int_{-\infty}^{\infty} e^{\mathbb{J}\omega\tau} (-\mathbb{J}\operatorname{sgn}(\omega)) S_X(\omega) d\omega \\ R_{X\tilde{X}}(\tau) &= \mathbb{E}\left[X(t+\tau)\overline{\tilde{X}(t)}\right] = \frac{1}{2\pi} \int_{-\infty}^{\infty} e^{\mathbb{J}\omega\tau} (\mathbb{J}\operatorname{sgn}(\omega)) S_X(\omega) d\omega\end{aligned}$$

Gauss 过程

Gauss 过程的引入

多元 Gauss 分布

对于多维随机变量 $\vec{X} = (X_1 \ X_2 \ \cdots \ X_n)^T$ ，如果 $\mathbb{E}[|X_k|^2] < \infty$ ，则其**均值向量 (mean vector)** 定义为

$$\vec{\mu} = \mathbb{E}[\vec{X}] = (\mathbb{E}[X_1] \ \mathbb{E}[X_2] \ \cdots \ \mathbb{E}[X_n])^T$$

其**协方差矩阵 (covariance matrix)** 定义为

$$\Sigma = \mathbb{E}\left[(\vec{X} - \vec{\mu})(\vec{X} - \vec{\mu})^T\right] = \left(\mathbb{E}[(X_i - \mathbb{E}[X_i])(X_j - \mathbb{E}[X_j])]\right)_{i,j}$$

Def. 多元 Gauss 分布

设 $\vec{X} = (X_1 \ X_2 \ \cdots \ X_n)^T$ 是 n 维随机变量，如果 $\vec{X}$ 的联合概率密度函数形如

$$f_{\vec{X}}(\vec{x}) = k \exp\left(-\frac{1}{2}(\vec{x} - \vec{\mu})^T \Sigma^{-1}(\vec{x} - \vec{\mu})\right)$$

则称 $\vec{X}$ 服从 n 元 **Gauss 分布 (Gaussian distribution)**，记为 $\vec{X} \sim N(\vec{\mu}, \Sigma)$ ，其中 $k \in \mathbb{R}$ ， $\vec{\mu} \in \mathbb{R}^n$ ， $\Sigma \in \mathbb{R}^{n \times n}$ 对称正定。

多元 Gauss 分布的归一化

由 Σ 对称正定，可知 Σ 可对角化，即存在正交矩阵 U 和对角矩阵 $A = \operatorname{diag}(\lambda_1, \lambda_2, \dots, \lambda_n)$ ，使得

$$\Sigma = UAU^T$$

其中 $\lambda_1, \lambda_2, \dots, \lambda_n > 0$ 是 Σ 的特征值。此处引入

$$B = A^{-1/2} U^T$$

则 $\Sigma^{-1} = BB^T$ ，进而

$$\begin{aligned}(\vec{x} - \vec{\mu})^T \Sigma^{-1}(\vec{x} - \vec{\mu}) &= (\vec{x} - \vec{\mu})^T (BB^T)(\vec{x} - \vec{\mu}) \\ &= (B(\vec{x} - \vec{\mu}))^T (B(\vec{x} - \vec{\mu}))\end{aligned}$$

可做变量替换 $\vec{y} = B(\vec{x} - \vec{\mu}) = A^{-1/2} U^T(\vec{x} - \vec{\mu})$ ，这一变换的 Jacobian 行列式为

$$\left| \frac{\partial \vec{y}}{\partial \vec{x}} \right| = |\det B| = |\det A|^{-1/2} |\det U| = |\det \Sigma|^{-1/2}$$

尝试**确定归一化系数 k** ，归一化条件要求

$$\begin{aligned}1 &= \int_{\mathbb{R}^n} f_{\vec{X}}(\vec{x}) d\vec{x} = k \int_{\mathbb{R}^n} \exp\left(-\frac{1}{2}(\vec{x} - \vec{\mu})^T \Sigma^{-1}(\vec{x} - \vec{\mu})\right) d\vec{x} \\ &= k \int_{\mathbb{R}^n} \exp\left(-\frac{1}{2}\vec{y}^T \vec{y}\right) |\det \Sigma|^{1/2} d\vec{y} \\ &= k |\det \Sigma|^{1/2} \prod_{i=1}^n \int_{-\infty}^{\infty} \exp\left(-\frac{1}{2}y_i^2\right) dy_i = k |\det \Sigma|^{1/2} (2\pi)^{n/2}\end{aligned}$$

故 $k = (2\pi)^{-n/2} |\det \Sigma|^{-1/2}$ ，多元 Gauss 分布的概率密度函数为

$$f_{\vec{X}}(\vec{x}) = \frac{1}{(2\pi)^{n/2} |\det \Sigma|^{1/2}} \exp\left(-\frac{1}{2}(\vec{x} - \vec{\mu})^T \Sigma^{-1}(\vec{x} - \vec{\mu})\right)$$

特别地，**二维 Gauss 分布** 的协方差矩阵常记为 $\Sigma = \begin{pmatrix} \sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2 \end{pmatrix}$ ，其中 $\sigma_1^2 > 0$ ， $\sigma_2^2 > 0$ ， $-1 < \rho < 1$ ，此时其概率密度函数为

$$f_{\vec{X}}(\vec{x}) = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} \cdot \exp\left(-\frac{1}{2(1-\rho^2)}\left(\frac{(x_1-\mu_1)^2}{\sigma_1^2} - \frac{2\rho(x_1-\mu_1)(x_2-\mu_2)}{\sigma_1\sigma_2} + \frac{(x_2-\mu_2)^2}{\sigma_2^2}\right)\right)$$

多元 Gauss 分布的特征函数

对随机向量 $\vec{X} \in \mathbb{R}^n$ ，引入 $\vec{\omega} \in \mathbb{R}^n$ 的函数

$$\phi_{\vec{X}}(\vec{\omega}) = \mathbb{E}\left[\exp(\mathbb{J}\vec{\omega}^T \vec{X})\right] = \int_{\mathbb{R}^n} \exp(\mathbb{J}\vec{\omega}^T \vec{x}) f_{\vec{X}}(\vec{x}) d\vec{x}$$

称为 $\vec{X}$ 的**特征函数 (characteristic function)**。

对多元 Gauss 分布，有

$$\begin{aligned}\phi_{\vec{X}}(\vec{\omega}) &= \int_{\mathbb{R}^n} \exp(\mathbb{J}\vec{\omega}^T \vec{x}) f_{\vec{X}}(\vec{x}) d\vec{x} \\ &= \frac{1}{(2\pi)^{n/2} |\det \Sigma|^{1/2}} \int_{\mathbb{R}^n} \exp\left(\mathbb{J}\vec{\omega}^T \vec{x} - \frac{1}{2}(\vec{x} - \vec{\mu})^T \Sigma^{-1}(\vec{x} - \vec{\mu})\right) d\vec{x}\end{aligned}$$

为计算上面积分，首先考虑一元情况，可配方得到

$$\begin{aligned}\mathbb{J}\omega x - \frac{1}{2\sigma^2}(x - \mu)^2 &= -\frac{1}{2\sigma^2}(x^2 - 2(\mu + \mathbb{J}\sigma^2\omega)x + \mu^2) \\ &= -\frac{1}{2\sigma^2}(x - \mu - \mathbb{J}\sigma^2\omega)^2 + \mathbb{J}\mu\omega - \frac{1}{2}\sigma^2\omega^2\end{aligned}$$

类似地，对多元情况，有

$$\begin{aligned} & \mathbf{\bar{w}}^T \mathbf{\bar{x}} - \frac{1}{2} (\mathbf{\bar{x}} - \mathbf{\bar{\mu}})^T \mathbf{\Sigma}^{-1} (\mathbf{\bar{x}} - \mathbf{\bar{\mu}}) \\ &= -\frac{1}{2} (\mathbf{\bar{x}} - \mathbf{\bar{\mu}} - \mathbf{\bar{\mu}}^T \mathbf{\Sigma} \mathbf{\bar{w}})^T \mathbf{\Sigma}^{-1} (\mathbf{\bar{x}} - \mathbf{\bar{\mu}} - \mathbf{\bar{\mu}}^T \mathbf{\Sigma} \mathbf{\bar{w}}) + \mathbf{\bar{\mu}}^T \mathbf{\bar{w}} - \frac{1}{2} \mathbf{\bar{w}}^T \mathbf{\Sigma} \mathbf{\bar{w}} \end{aligned}$$

因此

$$\begin{aligned} \phi_{\bar{\mathbf{x}}}(\bar{\mathbf{w}}) &= \frac{1}{(2\pi)^{n/2} |\det \mathbf{\Sigma}|^{1/2}} \exp \left(\mathbf{\bar{\mu}}^T \mathbf{\bar{w}} - \frac{1}{2} \mathbf{\bar{w}}^T \mathbf{\Sigma} \mathbf{\bar{w}} \right) \\ &\quad \cdot \int_{\mathbb{R}^n} \exp \left(-\frac{1}{2} (\mathbf{\bar{x}} - \mathbf{\bar{\mu}} - \mathbf{\bar{\mu}}^T \mathbf{\Sigma} \mathbf{\bar{w}})^T \mathbf{\Sigma}^{-1} (\mathbf{\bar{x}} - \mathbf{\bar{\mu}} - \mathbf{\bar{\mu}}^T \mathbf{\Sigma} \mathbf{\bar{w}}) \right) d\mathbf{\bar{x}} \\ &= \exp \left(\mathbf{\bar{\mu}}^T \mathbf{\bar{w}} - \frac{1}{2} \mathbf{\bar{w}}^T \mathbf{\Sigma} \mathbf{\bar{w}} \right) \end{aligned}$$

综上所述, **多元 Gauss 分布的特征函数**为

$$\phi_{\bar{\mathbf{x}}}(\bar{\mathbf{w}}) = \exp \left(\mathbf{\bar{\mu}}^T \mathbf{\bar{w}} - \frac{1}{2} \mathbf{\bar{w}}^T \mathbf{\Sigma} \mathbf{\bar{w}} \right)$$

$X_1, X_2, \dots, X_n$ 相互独立的充分必要条件是协方差矩阵 $\mathbf{\Sigma}$ 为对角矩阵, 此时

$$\phi_{\bar{\mathbf{x}}}(\bar{\mathbf{w}}) = \prod_{i=1}^n \exp \left(\mathbf{\bar{\mu}}_i \omega_i - \frac{1}{2} \sigma_i^2 \omega_i^2 \right) = \prod_{i=1}^n \phi_{X_i}(\omega_i)$$

► 多元 Gauss 分布的性质

Gauss 变量的分布**完全由其一、二阶矩 $\bar{\mu}$ 、 Σ 决定**, 因此

- **高阶矩**均可由 $\bar{\mu}$ 、 Σ 表示, 如零均值 Gauss 变量的四阶矩

$$\begin{aligned} \mathbb{E}[X_i X_j X_k X_l] &= \Sigma_{i,j} \Sigma_{k,l} + \Sigma_{i,k} \Sigma_{j,l} + \Sigma_{i,l} \Sigma_{j,k} \\ &= \mathbb{E}[X_i X_j] \mathbb{E}[X_k X_l] + \mathbb{E}[X_i X_k] \mathbb{E}[X_j X_l] + \mathbb{E}[X_i X_l] \mathbb{E}[X_j X_k] \end{aligned}$$
- **线性变换**对 $\bar{\mu}$ 、 Σ 的影响是线性的, 因而对整个分布的影响也是线性的, 如 $\tilde{\mathbf{Y}} = \mathbf{A}\tilde{\mathbf{X}} + \tilde{\mathbf{b}}$, 则 $\tilde{\mathbf{Y}} \sim \mathcal{N}(\mathbf{A}\bar{\mu} + \tilde{\mathbf{b}}, \mathbf{A}\Sigma\mathbf{A}^T)$, 称为**线性变换不变性**。这是 Gauss 分布的**特征性质**。

■ Gauss 过程的定义

(*) Def. Gauss 过程

设 $X(t)$ 是定义在概率空间 $(\Omega, \mathcal{F}, P)$ 上的随机过程。如果对于任意正整数 n 和任意时刻 $t_1, t_2, \dots, t_n$, 随机变量组 $\tilde{\mathbf{X}} = (X(t_1) \ X(t_2) \ \dots \ X(t_n))^T$ 都服从 n 元 Gauss 分布 $\mathcal{N}(\bar{\mu}, \Sigma)$, 则称 $X(t)$ 为 **Gauss 过程 (Gaussian process)**。

由定义, Gauss 过程的**有限维分布**都是多元 Gauss 分布, 因此多元 Gauss 分布的性质均适用于 Gauss 过程。例如, Gauss 过程 $X(t)$ **通过一般线性系统 $b(t, \tau)$** 得到的**输出 $Y(t)$** 仍然是 **Gauss 过程**, 且

$$\begin{aligned} \mathbb{E}[Y(t)] &= \int_{-\infty}^{\infty} b(t, \tau) \mathbb{E}[X(\tau)] d\tau, \\ \text{Cov}[Y(t_1), Y(t_2)] &= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} b(t_1, \tau_1) b(t_2, \tau_2) \text{Cov}[X(\tau_1), X(\tau_2)] d\tau_1 d\tau_2 \end{aligned}$$

► Gauss 条件分布

考虑多维随机变量 $\tilde{\mathbf{X}} \in \mathbb{R}^m$ 、 $\tilde{\mathbf{Y}} \in \mathbb{R}^n$, 设其联合服从 $(m+n)$ 元 Gauss 分布 $\mathcal{N}(\bar{\mu}, \Sigma)$, 其中

$$\bar{\mu} = \begin{pmatrix} \bar{\mu}_X \\ \bar{\mu}_Y \end{pmatrix}, \quad \Sigma = \begin{pmatrix} \Sigma_{XX} & \Sigma_{XY} \\ \Sigma_{YX} & \Sigma_{YY} \end{pmatrix}$$

我们考察 $\tilde{\mathbf{Y}}$ **相对于 $\tilde{\mathbf{X}}$ 的条件分布**, 即考察

$$f_{\tilde{\mathbf{Y}}|\tilde{\mathbf{X}}}(\tilde{\mathbf{y}} | \tilde{\mathbf{x}}) = \frac{f_{\tilde{\mathbf{X}}, \tilde{\mathbf{Y}}}(\tilde{\mathbf{x}}, \tilde{\mathbf{y}})}{f_{\tilde{\mathbf{X}}}(\tilde{\mathbf{x}})}$$

其中, 由 $\tilde{\mathbf{X}}$ 也服从 Gauss 分布, 概率密度为

$$f_{\tilde{\mathbf{X}}}(\tilde{\mathbf{x}}) = k_X \exp \left(-\frac{1}{2} (\tilde{\mathbf{x}} - \bar{\mu}_X)^T \Sigma_{XX}^{-1} (\tilde{\mathbf{x}} - \bar{\mu}_X) \right)$$

$\tilde{\mathbf{X}}$ 和 $\tilde{\mathbf{Y}}$ 的联合概率分布为

$$f_{\tilde{\mathbf{X}}, \tilde{\mathbf{Y}}}(\tilde{\mathbf{x}}, \tilde{\mathbf{y}}) = k \exp \left(-\frac{1}{2} \begin{pmatrix} \tilde{\mathbf{x}} - \bar{\mu}_X \\ \tilde{\mathbf{y}} - \bar{\mu}_Y \end{pmatrix}^T \Sigma^{-1} \begin{pmatrix} \tilde{\mathbf{x}} - \bar{\mu}_X \\ \tilde{\mathbf{y}} - \bar{\mu}_Y \end{pmatrix} \right)$$

其中 k 和 k_X 是归一化系数。

■ 条件概率密度的计算

为计算条件概率密度, 首先需计算 Σ^{-1} 。如果能够把右上角块 Σ_{XY} 和左下角块 Σ_{YX} 消去, 则可将 Σ^{-1} 写成**分块对角矩阵**的形式, 从而简化计算。为此, 考虑如下初等变换:

$$\begin{pmatrix} \mathbf{I}_m & \\ \mathbf{B} & \mathbf{I}_n \end{pmatrix} \begin{pmatrix} \Sigma_{XX} & \Sigma_{XY} \\ \Sigma_{YX} & \Sigma_{YY} \end{pmatrix} \begin{pmatrix} \mathbf{I}_m & \mathbf{A} \\ & \mathbf{I}_n \end{pmatrix} = \begin{pmatrix} \mathbf{C} & \\ & \mathbf{D} \end{pmatrix}$$

$$\begin{pmatrix} \Sigma_{XX} & \Sigma_{XY} \\ \mathbf{B}\Sigma_{XX} + \Sigma_{YX} & \mathbf{B}\Sigma_{XY} + \Sigma_{YY} \end{pmatrix}$$

则右上角块为

$$\Sigma_{XX}\mathbf{A} + \Sigma_{XY} = \mathbf{O} \implies \mathbf{A} = -\Sigma_{XX}^{-1}\Sigma_{XY}$$

左下角块为

$$\mathbf{B}\Sigma_{XX} + \Sigma_{YX} = \mathbf{O} \implies \mathbf{B} = -\Sigma_{YX}\Sigma_{XX}^{-1}$$

因此, 有

$$\begin{pmatrix} \mathbf{I}_m & \\ -\Sigma_{YX}\Sigma_{XX}^{-1} & \mathbf{I}_n \end{pmatrix} \Sigma \begin{pmatrix} \mathbf{I}_m & -\Sigma_{XX}^{-1}\Sigma_{XY} \\ & \mathbf{I}_n \end{pmatrix} = \begin{pmatrix} \Sigma_{XX} & \\ & \Sigma_{YY} - \Sigma_{YX}\Sigma_{XX}^{-1}\Sigma_{XY} \end{pmatrix}$$

得

$$\Sigma = \begin{pmatrix} \mathbf{I}_m & \\ -\Sigma_{YX}\Sigma_{XX}^{-1} & \mathbf{I}_n \end{pmatrix}^{-1} \begin{pmatrix} \Sigma_{XX} & \\ & \Sigma_{YY} - \Sigma_{YX}\Sigma_{XX}^{-1}\Sigma_{XY} \end{pmatrix} \begin{pmatrix} \mathbf{I}_m & -\Sigma_{XX}^{-1}\Sigma_{XY} \\ & \mathbf{I}_n \end{pmatrix}^{-1}$$

进而

$$\Sigma^{-1} = \begin{pmatrix} \mathbf{I}_m & -\Sigma_{XX}^{-1}\Sigma_{XY} \\ & \mathbf{I}_n \end{pmatrix} \begin{pmatrix} \Sigma_{XX}^{-1} & \\ & (\Sigma_{YY} - \Sigma_{YX}\Sigma_{XX}^{-1}\Sigma_{XY})^{-1} \end{pmatrix} \begin{pmatrix} \mathbf{I}_m & \\ -\Sigma_{YX}\Sigma_{XX}^{-1} & \mathbf{I}_n \end{pmatrix}$$

这样, **联合概率密度**指数部分中的**二次型**可写成

$$\begin{aligned} & (\tilde{\mathbf{x}}^T - \bar{\mu}_X^T \quad \tilde{\mathbf{y}}^T - \bar{\mu}_Y^T) \Sigma^{-1} \begin{pmatrix} \tilde{\mathbf{x}} - \bar{\mu}_X \\ \tilde{\mathbf{y}} - \bar{\mu}_Y \end{pmatrix} \\ &= (\tilde{\mathbf{x}}^T - \bar{\mu}_X^T \quad \tilde{\mathbf{y}}^T - \bar{\mu}_Y^T) \begin{pmatrix} \mathbf{I}_m & -\Sigma_{XX}^{-1}\Sigma_{XY} \\ & \mathbf{I}_n \end{pmatrix} \\ &\quad \begin{pmatrix} \Sigma_{XX}^{-1} & \\ & (\Sigma_{YY} - \Sigma_{YX}\Sigma_{XX}^{-1}\Sigma_{XY})^{-1} \end{pmatrix} \begin{pmatrix} \mathbf{I}_m & \\ -\Sigma_{YX}\Sigma_{XX}^{-1} & \mathbf{I}_n \end{pmatrix} \begin{pmatrix} \tilde{\mathbf{x}} - \bar{\mu}_X \\ \tilde{\mathbf{y}} - \bar{\mu}_Y \end{pmatrix} \\ &= (\tilde{\mathbf{x}}^T - \bar{\mu}_X^T \quad \tilde{\mathbf{y}}^T - \bar{\mu}_Y^T - (\tilde{\mathbf{x}}^T - \bar{\mu}_X^T) \Sigma_{XX}^{-1}\Sigma_{XY}) \\ &\quad \begin{pmatrix} \Sigma_{XX}^{-1} & \\ & (\Sigma_{YY} - \Sigma_{YX}\Sigma_{XX}^{-1}\Sigma_{XY})^{-1} \end{pmatrix} \begin{pmatrix} \tilde{\mathbf{x}} - \bar{\mu}_X \\ \tilde{\mathbf{y}} - \bar{\mu}_Y - \Sigma_{YX}\Sigma_{XX}^{-1}(\tilde{\mathbf{x}} - \bar{\mu}_X) \end{pmatrix} \\ &= (\tilde{\mathbf{x}}^T - \bar{\mu}_X^T) \Sigma_{XX}^{-1} (\tilde{\mathbf{x}} - \bar{\mu}_X) \\ &\quad + (\tilde{\mathbf{y}}^T - \bar{\mu}_Y^T - (\tilde{\mathbf{x}}^T - \bar{\mu}_X^T) \Sigma_{XX}^{-1}\Sigma_{XY}) (\Sigma_{YY} - \Sigma_{YX}\Sigma_{XX}^{-1}\Sigma_{XY})^{-1} \\ &\quad \cdot (\tilde{\mathbf{y}} - \bar{\mu}_Y - \Sigma_{YX}\Sigma_{XX}^{-1}(\tilde{\mathbf{x}} - \bar{\mu}_X)) \end{aligned}$$

于是, **条件概率密度**的指数部分即为

$$\begin{aligned} & \left(-\frac{1}{2} \begin{pmatrix} \tilde{\mathbf{x}} - \bar{\mu}_X \\ \tilde{\mathbf{y}} - \bar{\mu}_Y \end{pmatrix}^T \Sigma^{-1} \begin{pmatrix} \tilde{\mathbf{x}} - \bar{\mu}_X \\ \tilde{\mathbf{y}} - \bar{\mu}_Y \end{pmatrix} \right) - \left(-\frac{1}{2} (\tilde{\mathbf{x}} - \bar{\mu}_X)^T \Sigma_{XX}^{-1} (\tilde{\mathbf{x}} - \bar{\mu}_X) \right) \\ &= -\frac{1}{2} (\tilde{\mathbf{y}}^T - \bar{\mu}_Y^T - (\tilde{\mathbf{x}}^T - \bar{\mu}_X^T) \Sigma_{XX}^{-1}\Sigma_{XY}) \\ &\quad \cdot \underbrace{(\Sigma_{YY} - \Sigma_{YX}\Sigma_{XX}^{-1}\Sigma_{XY})^{-1}}_{\Sigma_{Y|X}} \underbrace{(\tilde{\mathbf{y}} - (\bar{\mu}_Y + \Sigma_{YX}\Sigma_{XX}^{-1}(\tilde{\mathbf{x}} - \bar{\mu}_X)))}_{\bar{\mu}_{Y|X}} \\ &= -\frac{1}{2} (\tilde{\mathbf{y}} - \bar{\mu}_{Y|X})^T \Sigma_{Y|X}^{-1} (\tilde{\mathbf{y}} - \bar{\mu}_{Y|X}) \end{aligned}$$

■ *Thm.* 多元 Gauss 分布各块间的条件分布

设多维随机变量 $\tilde{\mathbf{X}} \in \mathbb{R}^m$ 、 $\tilde{\mathbf{Y}} \in \mathbb{R}^n$ 的联合服从 $(m+n)$ 元 Gauss 分布 $\mathcal{N}(\bar{\mu}, \Sigma)$, 其中

$$\bar{\mu} = \begin{pmatrix} \bar{\mu}_X \\ \bar{\mu}_Y \end{pmatrix}, \quad \Sigma = \begin{pmatrix} \Sigma_{XX} & \Sigma_{XY} \\ \Sigma_{YX} & \Sigma_{YY} \end{pmatrix}$$

则 $\tilde{\mathbf{Y}}$ 相对于 $\tilde{\mathbf{X}}$ 的条件分布仍然服从 Gauss 分布, 概率密度为

$$f_{\tilde{\mathbf{Y}}|\tilde{\mathbf{X}}}(\tilde{\mathbf{y}} | \tilde{\mathbf{x}}) = k_{Y|X} \exp \left(-\frac{1}{2} (\tilde{\mathbf{y}} - \bar{\mu}_{Y|X})^T \Sigma_{Y|X}^{-1} (\tilde{\mathbf{y}} - \bar{\mu}_{Y|X}) \right)$$

即 $\tilde{\mathbf{Y}} | \tilde{\mathbf{X}} \sim \mathcal{N}(\bar{\mu}_{Y|X}, \Sigma_{Y|X})$, 其中

$$\bar{\mu}_{Y|X} = \bar{\mu}_Y + \Sigma_{YX}\Sigma_{XX}^{-1}(\tilde{\mathbf{x}} - \bar{\mu}_X), \quad \Sigma_{Y|X} = \Sigma_{YY} - \Sigma_{YX}\Sigma_{XX}^{-1}\Sigma_{XY}$$

特别地，对二维情形 $\begin{pmatrix} X \\ Y \end{pmatrix} \sim \mathcal{N}\left(\begin{pmatrix} \mu_X \\ \mu_Y \end{pmatrix}, \begin{pmatrix} \sigma_X^2 & \rho\sigma_X\sigma_Y \\ \rho\sigma_X\sigma_Y & \sigma_Y^2 \end{pmatrix}\right)$ ，则有

$$\begin{aligned}\mathbb{E}[Y|X] &= \mu_{Y|X} = \mu_Y + \rho \frac{\sigma_Y}{\sigma_X}(X - \mu_X), \\ \text{Var}[Y|X] &= \sigma_{Y|X}^2 = (1 - \rho^2)\sigma_Y^2\end{aligned}$$

≡ **Ex. 例题** > L10-1 至 L10-7: Gauss 条件分布算例

设 $X_1, X_2 \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(0, 1)$ ，尝试求解以下条件期望。

- 直接求解：
 - 例题 > L10-1** $\mathbb{E}[X_1 - X_2 | X_1 + X_2]$;
- 利用独立性简化计算：
 - 例题 > L10-2** $\mathbb{E}[(X_1 - X_2)^2 | X_1 + X_2]$;
 - 例题 > L10-3** $\mathbb{E}[(X_1 - X_2)^{2n} | X_1 + X_2]$, $n \in \mathbb{N}^*$;
 - 例题 > L10-4** $\mathbb{E}[X_1^2 + X_2^2 | X_1 + X_2]$;
- 利用特征函数简化计算：
 - 例题 > L10-5** $\mathbb{E}[\exp(2X_1 - X_2) | X_1 + X_2]$;
 - 例题 > L10-6** $\mathbb{E}[\exp(2X_1^2 + X_2^2) | X_1 - X_2]$;
 - 例题 > L10-7** $\mathbb{E}[\sin(2X_1 - X_2) | X_1 + X_2]$ 。

■ 条件分布的几何直观

观察条件均值 $\vec{\mu}_{Y|X}$ 的表达式

$$\vec{\mu}_{Y|X} = \vec{\mu}_Y + \boldsymbol{\Sigma}_{YX} \boldsymbol{\Sigma}_{XX}^{-1} (\vec{x} - \vec{\mu}_X)$$

其可视为对无条件均值 $\vec{\mu}_Y$ 的修正，且

- 修正量与 $\vec{x}$ 偏离其均值 $\vec{\mu}_X$ 的程度 $(\vec{x} - \vec{\mu}_X)$ ，即 $\vec{x}$ 中的随机成分成正比；
- 修正量与上述随机成分的**比例系数**为 $\boldsymbol{\Sigma}_{YX} \boldsymbol{\Sigma}_{XX}^{-1}$ ，其中 $\boldsymbol{\Sigma}_{XX}^{-1}$ 起到「标准化」的作用，而 $\boldsymbol{\Sigma}_{YX}$ 则反映了 $\vec{x}$ 和 $\vec{y}$ 之间的**相关性**。

因此， $\vec{y}$ 相对于 $\vec{x}$ 的条件分布可看做依据 $\vec{x}$ 的随机成分在 $\vec{y}$ 上的**投影 (projection)** 对 $\vec{y}$ 的分布进行调整后的结果。

▀ Gauss 过程通过非线性系统

■ 典型非线性系统下的 Gauss 过程

非线性系统的解析结构通常较为复杂，难以泛泛讨论其对 Gauss 过程的影响，需要具体问题具体分析。

≡ **Ex. 例题** > L11-1: Gauss 过程通过理想限幅器

理想限幅器 (ideal limiter) 定义为

$$g(x) = \begin{cases} -1, & x < 0, \\ 1, & x \geq 0 \end{cases}$$

≡ **Ex. 例题** > L11-2: Gauss 过程通过全波线性检波器

全波线性检波器 (full-wave rectifier) 定义为

$$g(x) = |x| = \begin{cases} -x, & x < 0, \\ x, & x \geq 0 \end{cases}$$

≡ **Ex. 例题** > L11-3: Gauss 过程通过半波线性检波器

半波线性检波器 (half-wave rectifier) 定义为

$$g(x) = \begin{cases} 0, & x < 0, \\ x, & x \geq 0 \end{cases} = \text{ReLU}(x)$$

≡ **Ex. 例题** > L11-4: Gauss 过程通过平方律检波器

平方律检波器 (square-law detector) 即 $g(x) = x^2$ 。

■ Price 定理

Price 定理是分析 Gauss 过程通过非线性系统后输出统计特性的有力工具。

≡ **Thm. Price 定理**

设 (X, Y) 服从二元 Gauss 分布 $\mathcal{N}(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$ ， $r = \text{Cov}(X, Y) = \rho\sigma_1\sigma_2$ ， $g(x, y)$ 是满足一定正则性条件的二元函数，则

$$\frac{\partial^n}{\partial r^n} \mathbb{E}[g(X, Y)] = \mathbb{E}\left[\frac{\partial^{2n} g(X, Y)}{\partial x^n \partial y^n}\right]$$

特别地， $n = 1$ 时即

$$\frac{\partial}{\partial \rho} \mathbb{E}[g(X, Y)] = \sigma_1 \sigma_2 \mathbb{E}\left[\frac{\partial^2 g(X, Y)}{\partial x \partial y}\right]$$

使用 Price 定理的核心是，选取合适的函数 $g(x, y)$ ，从而**将待求的统计量 $\mathbb{E}[Y(t)Y(s)]$ 表示为 $\mathbb{E}[g(X(t), X(s))]$** ，以使用 $\mathbb{E}[X(t)X(s)]$ 简化计算。通常直接选取 $g(x, y) = g(x)g(y)$ ，其中 $g(\cdot)$ 为非线性系统的输入输出关系。

Gauss 过程的 **Bussgang 性质 (Bussgang property)** 是 Price 定理的一个重要推论，描述了 Gauss 过程通过非线性系统后输出与输入之间的相关性关系。

≡ **Thm. Bussgang 性质**

设 (X, Y) 服从零均值二元 Gauss 分布， $b(\cdot)$ 为满足一定正则性条件的无记忆非线性函数，则

$$\mathbb{E}[Xb(Y)] = C\mathbb{E}[XY]$$

其中 C 是仅依赖于 Y 的常数，具体为 $C = \frac{\mathbb{E}[Yb(Y)]}{\mathbb{E}[Y^2]} = \mathbb{E}\left[\frac{d}{dY}b(Y)\right]$ 。

▀ † 窄带 Gauss 过程

■ 二维 Gauss 分布的幅度分布

设 $\begin{pmatrix} X \\ Y \end{pmatrix} \sim \mathcal{N}(\vec{\mu}, \sigma^2 \mathbf{I})$ ，不失一般性地设 $\vec{\mu} = \begin{pmatrix} A \cos \phi \\ A \sin \phi \end{pmatrix}$ ，则联合概率密度为

$$\begin{aligned}f_{X,Y}(x, y) &= \frac{1}{2\pi\sigma^2} \exp\left(-\frac{1}{2\sigma^2}((x - A \cos \phi)^2 + (y - A \sin \phi)^2)\right) \\ &= \frac{1}{2\pi\sigma^2} \exp\left(-\frac{1}{2\sigma^2}(x^2 + y^2 + A^2 - 2A(x \cos \phi + y \sin \phi))\right)\end{aligned}$$

转换到**极坐标系** (R, θ) ，其中 $R = \sqrt{X^2 + Y^2}$ 、 $\theta = \arctan \frac{Y}{X}$ ，则

$$\begin{aligned}f_{R,\theta}(r, \theta) &= f_{X,Y}(r \cos \theta, r \sin \theta) \left| \frac{D(x, y)}{D(r, \theta)} \right| \\ &= \frac{r}{2\pi\sigma^2} \exp\left(-\frac{1}{2\sigma^2}(r^2 + A^2 - 2Ar \cos(\theta - \phi))\right)\end{aligned}$$

对 θ 积分即得到幅度 R 的概率密度

$$\begin{aligned}f_R(r) &= \int_0^{2\pi} f_{R,\theta}(r, \theta) d\theta \\ &= \frac{r}{2\pi\sigma^2} \exp\left(-\frac{r^2 + A^2}{2\sigma^2}\right) \int_0^{2\pi} \exp\left(\frac{Ar}{\sigma^2} \cos(\theta - \phi)\right) d\theta \\ &= \frac{r}{\sigma^2} \exp\left(-\frac{r^2 + A^2}{2\sigma^2}\right) I_0\left(\frac{Ar}{\sigma^2}\right), \quad r \geq 0\end{aligned}$$

称 R 服从 **Rician 分布**；当 $A = 0$ 时， R 的概率密度化为

$$f_R(r) = \frac{r}{\sigma^2} \exp\left(-\frac{r^2}{2\sigma^2}\right), \quad r \geq 0$$

称 R 服从 **Rayleigh 分布**，此时 $f_{R,\theta}(r, \theta) = \frac{f_R(r)}{2\pi} = f_R(r)f_\theta(\theta)$ ，即幅度和相位**统计独立**。

■ 零均值窄带 Gauss 过程

设联合平稳的零均值实宽平稳 Gauss 过程 $X(t)$ 、 $Y(t)$ 满足：

- 相关函数 $R_X(\tau) = R_Y(\tau)$ ， $R_{XY}(\tau) = -R_{YX}(\tau)$ ；
- $|\omega| \geq \omega_0$ 上功率谱密度 $S_X(\omega) = S_Y(\omega) = 0$ 。

则可构造 Gauss 过程

$$Z(t) = X(t) \cos \omega_c t - Y(t) \sin \omega_c t = V(t) \cos (\omega_c t + \Theta(t))$$

称为零均值**窄带 Gauss 过程**，其中 $V(t) = \sqrt{X^2(t) + Y^2(t)}$ 为**包络过程**，

$\Theta(t) = \arctan \frac{Y(t)}{X(t)}$ 为**相位过程**，调制频率 $\omega_c \gg \omega_0$ 。

由**二维 Gauss 分布的幅度分布**中的结论立得， $V(t)$ 服从 **Rayleigh 分布**， $\Theta(t)$ 服从均匀分布，且 $V(t)$ 和 $\Theta(t)$ 统计独立。

■ 非零均值窄带 Gauss 过程

设窄带 Gauss 的非零均值是由**正弦波随机相位过程**叠加引入的，即考虑

$$\xi(t) = p \sin (\omega_c t + \Phi) + Z(t)$$

其中 p 为常数， Φ 为均匀分布在 $[0, 2\pi)$ 上的随机变量， $Z(t)$ 为**零均值窄带 Gauss 过程**。

$\xi(t)$ 可写成

$$\begin{aligned} \xi(t) &= \underbrace{p \sin \Phi}_{\mu_X} \cos \omega_c t + \underbrace{p \cos \Phi}_{\mu_Y} \sin \omega_c t + X(t) \cos \omega_c t - Y(t) \sin \omega_c t \\ &= (X(t) + \mu_X) \cos \omega_c t - (Y(t) - \mu_Y) \sin \omega_c t \\ &= V_\xi(t) \cos (\omega_c t + \Theta_\xi(t)) \end{aligned}$$

其中

$$V_\xi(t) \cos \Theta_\xi(t) = X(t) + p \sin \Phi, \quad V_\xi(t) \sin \Theta_\xi(t) = Y(t) - p \cos \Phi$$

则 $V_\xi(t)$ 服从 **Rician 分布**，概率密度为

$$f_{V_\xi}(v) = \frac{v}{\sigma^2} \exp \left(-\frac{v^2 + p^2}{2\sigma^2} \right) I_0 \left(\frac{pv}{\sigma^2} \right), \quad v \geq 0$$

Poisson 过程

► Poisson 过程的定义

Poisson 过程是一类**时间连续、状态离散**的随机过程，广泛应用于排队论、可靠性工程、通信系统等领域。它描述了在单位时间内某事件发生的次数，且这些事件是独立且均匀分布的。

■ 增量独立性、增量平稳性

一个随机过程 $X(t)$ 如果满足

$$\forall t_1 < t_2 \leq t_3 < t_4, \quad X(t_2) - X(t_1) \perp X(t_4) - X(t_3)$$

则称其具有**增量独立性 (independent increments)**。

此外，如果对于任意 $s, t, \tau \geq 0$ ，都有

$$X(t + \tau) - X(s + \tau) \stackrel{d}{=} X(t) - X(s)$$

其中 $\stackrel{d}{=}$ 表示**同分布 (equal in distribution)**，即 $X(t) - X(s)$ 的分布只与 $t - s$ 有关，而与具体的时间点无关，则称其具有**增量平稳性 (stationary increments)**。

■ 矩母函数

对于具有离散状态取值随机变量 $X(t)$ ，我们参照 **z 变换** 引入其**矩母函数 (moment generating function)**，定义为

$$G_{X(t)}(z) = \mathbb{E} \left[z^{X(t)} \right]$$

则 $G_{X(t)}(z)$ 可以展开为

$$G_{X(t)}(z) = \sum_{k=0}^{\infty} P\{X(t) = k\} \cdot z^k$$

即 $X(t)$ 取为每个 k 的概率都对应到**矩母函数相应阶项 z^k 的系数**上。

■ Poisson 过程的引入

设 $X(t)$ 是一个具有**增量独立性、增量平稳性**的随机过程，我们尝试**构造一个关于其矩母函数的微分方程**。

为此，我们求其矩母函数对时间的导数，即

$$\begin{aligned} \frac{d}{dt} G_{X(t)}(z) &= \lim_{\Delta t \rightarrow 0} \frac{G_{X(t+\Delta t)}(z) - G_{X(t)}(z)}{\Delta t} = \lim_{\Delta t \rightarrow 0} \frac{\mathbb{E} [z^{X(t+\Delta t)} - z^{X(t)}]}{\Delta t} \\ &= \lim_{\Delta t \rightarrow 0} \frac{\mathbb{E} [z^{X(t)} (z^{X(t+\Delta t)-X(t)} - 1)]}{\Delta t} \end{aligned}$$

令**初态 $X(0) = 0$** ，则由增量独立性有 $X(t) - X(0)$ 与 $X(t + \Delta t) - X(t)$ 独立，由增量平稳性有 $X(t + \Delta t) - X(t) \stackrel{d}{=} X(\Delta t)$ ，因此上式可写为

$$\begin{aligned} \frac{d}{dt} G_{X(t)}(z) &= \lim_{\Delta t \rightarrow 0} \frac{\mathbb{E} [z^{X(t)}] \cdot \mathbb{E} [z^{X(t+\Delta t)-X(t)} - 1]}{\Delta t} \\ &= G_{X(t)}(z) \cdot \lim_{\Delta t \rightarrow 0} \frac{\mathbb{E} [z^{X(\Delta t)} - 1]}{\Delta t} \\ &= G_{X(t)}(z) \cdot \lim_{\Delta t \rightarrow 0} \frac{1}{\Delta t} \left(\sum_{k=0}^{\infty} P\{X(\Delta t) = k\} \cdot z^k - 1 \right) \end{aligned}$$

括号中的因子可展开为

$$\begin{aligned} &\sum_{k=0}^{\infty} P\{X(\Delta t) = k\} \cdot z^k - 1 \\ &= \underbrace{P\{X(\Delta t) = 0\} - 1}_{\#1} + \underbrace{P\{X(\Delta t) = 1\} \cdot z^1}_{\#2} + \underbrace{\sum_{k=2}^{\infty} P\{X(\Delta t) = k\} \cdot z^k}_{\#3} \end{aligned}$$

分别处理上述三项。

► Term #1

注意到

$$\begin{aligned} P\{X(t) = 0\} &= P\{X(s) = 0, X(t) - X(s) = 0\} \quad (\forall s \in [0, t]) \\ &= P\{X(s) = 0\} \cdot P\{X(t) - X(s) = 0\} \\ &= P\{X(s) = 0\} \cdot P\{X(t - s) = 0\} \end{aligned}$$

因此， $H(t) = P\{X(t) = 0\}$ 满足**函数方程**

$$H(t) = H(s) \cdot H(t - s)$$

在**有界**的条件下，唯一解为**指数函数**，即知

$$P\{X(\Delta t) = 0\} = e^{-\lambda \Delta t}, \quad \lambda \geq 0$$

因此

$$\lim_{\Delta t \rightarrow 0} \frac{1}{\Delta t} (P\{X(\Delta t) = 0\} - 1) = \lim_{\Delta t \rightarrow 0} \frac{e^{-\lambda \Delta t} - 1}{\Delta t} = -\lambda$$

► Term #2

已知

$$P\{X(\Delta t) = 0\} + P\{X(\Delta t) = 1\} + P\{X(\Delta t) \geq 2\} = 1$$

即有

$$\frac{1 - P\{X(\Delta t) = 0\}}{\Delta t} = \frac{P\{X(\Delta t) = 1\}}{\Delta t} \left(1 + \frac{P\{X(\Delta t) \geq 2\}}{P\{X(\Delta t) = 1\}} \right)$$

为了使得上式在 $\Delta t \rightarrow 0$ 时有界，必须引入**稀疏性假设 (sparsity assumption)**，即要求

$$\lim_{\Delta t \rightarrow 0} \frac{1}{\Delta t} \frac{P\{X(\Delta t) \geq 2\}}{P\{X(\Delta t) = 1\}} = 0$$

在此假设下，有

$$\lim_{\Delta t \rightarrow 0} \frac{1}{\Delta t} P\{X(\Delta t) = 1\} = \lambda$$

► Term #3

我们先考察这个求和项的收敛，有

$$\begin{aligned} \left| \sum_{k=2}^{\infty} P\{X(\Delta t) = k\} \cdot z^k \right| &\leq \sum_{k=2}^{\infty} P\{X(\Delta t) = k\} \cdot |z|^k \\ &= \sum_{k=2}^{\infty} P\{X(\Delta t) = k\} = P\{X(\Delta t) \geq 2\} \end{aligned}$$

因此，在稀疏性假设下，有

$$\frac{\left| \sum_{k=2}^{\infty} P\{X(\Delta t) = k\} \cdot z^k \right|}{P\{X(\Delta t) = 1\}} \leq \frac{P\{X(\Delta t) \geq 2\}}{P\{X(\Delta t) = 1\}} \xrightarrow{\Delta t \rightarrow 0} o(\Delta t)$$

故由夹逼准则知

$$\lim_{\Delta t \rightarrow 0} \frac{1}{\Delta t} \cdot P\{X(\Delta t) = 1\} \cdot \frac{\sum_{k=2}^{\infty} P\{X(\Delta t) = k\} \cdot z^k}{P\{X(\Delta t) = 1\}} = 0$$

综上，将三项结果代入矩母函数的导数表达式中，得到

$$\frac{d}{dt} G_{X(t)}(z) = G_{X(t)}(z) \cdot (-\lambda + \lambda z + 0) = (-\lambda + \lambda z) G_{X(t)}(z)$$

该微分方程的初始条件为

$$G_{X(0)}(z) = \mathbb{E}[z^{X(0)}] = z^0 = 1$$

故解得

$$G_{X(t)}(z) = e^{(-\lambda + \lambda z)t} = e^{-\lambda t} \cdot e^{\lambda z t} = e^{-\lambda t} \sum_{k=0}^{\infty} \frac{(\lambda t)^k}{k!} z^k$$

对比[矩母函数](#)的定义式，可知

$$P\{X(t) = k\} = \frac{(\lambda t)^k}{k!} e^{-\lambda t}, \quad k = 0, 1, 2, \dots$$

这是一个以 λt 为参数的 **Poisson 分布**。

☞ Def. Poisson 过程

设 $N(t)$ 是一个随机过程，满足以下条件：

1. $N(t)$ 的取值为非负整数，且初态 $N(0) = 0$,
2. $N(t)$ 具有增量独立性和增量平稳性，
3. $N(t)$ 满足稀疏性假设，即 $\frac{P\{N(\Delta t) \geq 2\}}{P\{N(\Delta t) = 1\}} = o(\Delta t)$ ($\Delta t \rightarrow 0$),

则称 $N(t)$ 为 **Poisson 过程 (Poisson process)**，其概率分布为

$$P\{N(t) = k\} = \frac{(\lambda t)^k}{k!} e^{-\lambda t}, \quad k = 0, 1, 2, \dots$$

其中 $\lambda > 0$ 称为 Poisson 过程的强度 (intensity)。

由增量平稳性，概率分布也写为

$$P\{N(t) - N(s) = k\} = \frac{(\lambda(t-s))^k}{k!} e^{-\lambda(t-s)}, \quad k = 0, 1, 2, \dots$$

Poisson 过程的基本性质

■ 非宽平稳

由 Poisson 过程的概率分布可知

$$\mathbb{E}[N(t)] = \lambda t, \quad \text{Var}[N(t)] = \lambda t, \quad \mathbb{E}[N^2(t)] = \lambda t + (\lambda t)^2$$

Poisson 过程的相关函数为

$$R_N(t_1, t_2) = \mathbb{E}[N(t_1)N(t_2)] = \underbrace{\lambda \min(t_1, t_2)}_{C_N(t,s)} + \lambda^2 t_1 t_2$$

因此，Poisson 过程既不满足**均值平稳 (mean stationary)**，也不满足**相关平稳 (correlation stationary)**，故 Poisson 过程是一个**非宽平稳**的随机过程，我们需要借助其他方法来分析其性质。

■ 条件均值

设 $N(t)$ 是一个 Poisson 过程，且 $0 \leq s < t$ ，则**沿时间方向**有

$$\begin{aligned} \mathbb{E}[N(t) | N(s)] &= \mathbb{E}[N(t) - N(s) + N(s) | N(s)] \\ &= \mathbb{E}[N(t) - N(s) | N(s)] + \mathbb{E}[N(s) | N(s)] \\ &= \mathbb{E}[N(t) - N(s)] + N(s) = \lambda(t-s) + N(s) \end{aligned}$$

即 Poisson 过程的条件期望是**时间线性的**，事件继续发生的速率仍为 λ 。

反过来，我们考虑**逆时间方向**的条件概率分布，有

$$\begin{aligned} P\{N(s) = k | N(t) = n\} &= \frac{P\{N(s) = k, N(t) = n\}}{P\{N(t) = n\}} \\ &= \frac{P\{N(s) = k, N(t) - N(s) = n - k\}}{P\{N(t) = n\}} \\ &= \frac{P\{N(s) = k\} \cdot P\{N(t) - N(s) = n - k\}}{P\{N(t) = n\}} \\ &= \frac{\frac{(\lambda s)^k}{k!} e^{-\lambda s} \cdot \frac{(\lambda(t-s))^{n-k}}{(n-k)!} e^{-\lambda(t-s)}}{\frac{(\lambda t)^n}{n!} e^{-\lambda t}} \\ &= \binom{n}{k} \left(\frac{s}{t}\right)^k \left(1 - \frac{s}{t}\right)^{n-k} \end{aligned}$$

即在给定 $N(t) = n$ 的条件下，此前的 $N(s)$ 将转而服从**二项分布** $B\left(n, \frac{s}{t}\right)$ ，从而

$$\mathbb{E}[N(s) | N(t)] = N(t) \cdot \frac{s}{t}$$

同样也是时间线性的，但不同的是，此时的**系数与 Poisson 过程的强度 λ 无关**，因为 Poisson 过程的增量独立性使得过去的信息无法影响未来的分布，但已知的信息可以推测过去的分布。

■ 事件间隔

由增量独立性和增量平稳性，我们只需研究从初态开始到第一个事件的间隔 T_1 的分布，其定义为

$$F_{T_1}(t) = P\{T_1 \leq t\} = P\{N(t) \geq 1\} = 1 - P\{N(t) = 0\} = 1 - e^{-\lambda t}$$

因此

$$f_{T_1}(t) = \frac{d}{dt} F_{T_1}(t) = \lambda e^{-\lambda t}, \quad t \geq 0$$

于是事件间隔均服从参数为 λ 的**指数分布**，即 $\{T_k\} \stackrel{\text{i.i.d.}}{\sim} \text{Exp}(\lambda)$ ，有

$$\mathbb{E}[T_k] = \frac{1}{\lambda}, \quad \text{Var}[T_k] = \frac{1}{\lambda^2}$$

由独立性，容易得到事件间隔 $T_1, \dots, T_k$ 的**联合概率密度函数**为

$$f_{T_1, T_2, \dots, T_k}(t_1, t_2, \dots, t_k) = \prod_{i=1}^k f_{T_i}(t_i) = \lambda^k e^{-\lambda \sum_{i=1}^k t_i}, \quad t_i \geq 0$$

■ 等待时间

► 等待时间的边缘分布

设第 n 个事件发生的时间为 $S_n = \sum_{k=1}^n T_k$ 。引入**特征函数** $\phi_X(\omega) = \mathbb{E}[e^{j\omega X}]$ ，则由事件间隔的独立性，有

$$\phi_{T_k}(\omega) = \int_0^{\infty} \lambda e^{-\lambda t} \cdot e^{j\omega t} dt = \frac{\lambda}{\lambda - j\omega} \implies \phi_{S_n}(\omega) = (\phi_{T_k}(\omega))^n = \left(\frac{\lambda}{\lambda - j\omega}\right)^n$$

因此可以通过逆变换求得 S_n 的**概率密度函数**为

$$f_{S_n}(t) = \int_{-\infty}^{\infty} \phi_{S_n}(\omega) \cdot e^{-j\omega t} \frac{d\omega}{2\pi} = \begin{cases} \frac{\lambda(\lambda t)^{n-1}}{(n-1)!} e^{-\lambda t}, & t \geq 0, \\ 0, & t < 0 \end{cases}$$

此为参数为 (n, λ) 的**Erlang 分布 (Erlang distribution)**。

📌 Note 等待时间分布与 Poisson 过程概率分布的转换

设 $N(t)$ 是参数为 λ 的 Poisson 过程，第 n 个事件发生的时间为 S_n ，则有重要关系

$$P\{S_n \leq t\} = P\{N(t) \geq n\}, \quad P\{S_n > t\} = P\{N(t) < n\}$$

由此关系也可以导出等待时间的概率密度函数，即

$$\begin{aligned} F_{S_n}(t) &= P\{S_n \leq t\} = P\{N(t) \geq n\} = \sum_{k=n}^{\infty} P\{N(t) = k\} = \sum_{k=n}^{\infty} \frac{(\lambda t)^k}{k!} e^{-\lambda t} \\ f_{S_n}(t) &= \frac{d}{dt} F_{S_n}(t) = \sum_{k=n}^{\infty} \left(\frac{\lambda(\lambda t)^{k-1}}{(k-1)!} e^{-\lambda t} - \frac{\lambda(\lambda t)^k}{k!} e^{-\lambda t} \right) \\ &= \frac{\lambda(\lambda t)^{n-1}}{(n-1)!} e^{-\lambda t} + \lim_{n \rightarrow \infty} \frac{\lambda(\lambda t)^n}{n!} e^{-\lambda t} = \frac{\lambda(\lambda t)^{n-1}}{(n-1)!} e^{-\lambda t} \end{aligned}$$

为将 n 推广为任意正实数, 可引入 **Γ 函数** $\Gamma(\alpha) = \int_0^\infty t^{\alpha-1} e^{-t} dt$ 替代阶乘, 则 S_n 的概率密度函数可写为

$$f_{S_n}(t) = \begin{cases} \frac{\lambda(\lambda t)^{n-1}}{\Gamma(n)} e^{-\lambda t}, & t \geq 0, \\ 0, & t < 0 \end{cases}$$

此即参数为 (n, λ) 的 **Γ 分布 (Gamma distribution)**。

► 等待时间的联合分布

可以用**微元法**导出 $S_1, S_2, \dots, S_k$ 的联合概率密度函数。设 $0 < t_1 < t_2 < \dots < t_k$, 并取足够小的正数 $b_1, \dots, b_k$, 有

$$\begin{aligned} & P\{t_1 \leq S_1 < t_1 + b_1, t_2 \leq S_2 < t_2 + b_2, \dots, t_k \leq S_k < t_k + b_k\} \\ &= P\{N(t_1) = 0, N(t_1 + b_1) - N(t_1) = 1, N(t_2) - N(t_1 + b_1) = 0, \dots, \\ &\quad N(t_k) - N(t_{k-1} + b_{k-1}) = 0, N(t_k + b_k) - N(t_k) = 1\} \\ &= P\{N(t_1) = 0\} \cdot P\{N(t_1 + b_1) - N(t_1) = 1\} \cdots \\ &\quad \cdot P\{N(t_k) - N(t_{k-1} + b_{k-1}) = 0\} \cdot P\{N(t_k + b_k) - N(t_k) = 1\} \\ &= e^{-\lambda t_1} \cdot (\lambda b_1 e^{-\lambda b_1}) \cdot e^{-\lambda(t_2 - t_1 - b_1)} \cdots (\lambda b_k e^{-\lambda b_k}) \\ &= \lambda^k e^{-\lambda(t_k + b_k)} \cdot b_1 b_2 \cdots b_k \\ &\xrightarrow{b_i \rightarrow 0} f_{S_1, S_2, \dots, S_k}(t_1, t_2, \dots, t_k) \cdot b_1 b_2 \cdots b_k \end{aligned}$$

因此, 得到 $S_1, S_2, \dots, S_k$ 的联合概率密度函数

$$f_{S_1, S_2, \dots, S_k}(t_1, t_2, \dots, t_k) = \begin{cases} \lambda^k e^{-\lambda t_k}, & 0 < t_1 < t_2 < \dots < t_k, \\ 0, & \text{otherwise} \end{cases}$$

► 等待时间的条件分布

给定 $N(t) = n$, 考察前 n 个事件发生时间的条件联合分布。同样由微元法, 设 $0 < t_1 < t_2 < \dots < t_n < t$, 并取足够小的正数 $b_1, \dots, b_n$, 有

$$\begin{aligned} & P\{t_1 \leq S_1 < t_1 + b_1, t_2 \leq S_2 < t_2 + b_2, \dots, t_n \leq S_n < t_n + b_n \mid N(t) = n\} \\ &= \frac{P\{t_1 \leq S_1 < t_1 + b_1, t_2 \leq S_2 < t_2 + b_2, \dots, t_n \leq S_n < t_n + b_n, N(t) = n\}}{P\{N(t) = n\}} \\ &= \frac{P\{N(t_1) = 0, N(t_1 + b_1) - N(t_1) = 1, \dots, N(t) - N(t_n + b_n) = 0\}}{P\{N(t) = n\}} \\ &= \frac{\lambda^n e^{-\lambda(t_n + b_n)} \cdot b_1 b_2 \cdots b_n \cdot e^{-\lambda(t - t_n - b_n)}}{\frac{(\lambda t)^n}{n!} e^{-\lambda t}} = \frac{n!}{t^n} \cdot b_1 b_2 \cdots b_n \\ &\xrightarrow{b_i \rightarrow 0} f_{S_1, S_2, \dots, S_n \mid N(t)=n}(t_1, t_2, \dots, t_n) \cdot b_1 b_2 \cdots b_n \end{aligned}$$

即得到**条件联合概率密度函数**

$$f_{S_1, S_2, \dots, S_n \mid N(t)=n}(t_1, t_2, \dots, t_n) = \begin{cases} \frac{n!}{t^n}, & 0 < t_1 < t_2 < \dots < t_n < t, \\ 0, & \text{otherwise} \end{cases}$$

📝 Note 顺序统计量

设 $X_1, X_2, \dots, X_n$ 是来自某一分布 $F_X(x)$ 的 n 个独立同分布随机变量, 则将它们按从小到大的顺序排列, 记为 $Y_1 \leq Y_2 \leq \dots \leq Y_n$, 即称 $\{Y_i\}_{i=1}^n$ 为 $X_1, X_2, \dots, X_n$ 的**顺序统计量 (order statistics)**。第 k 顺序统计量 Y_k 即为 $X_1, X_2, \dots, X_n$ 中第 k 小的值。

对于两个极端情况, 容易得到

$$\begin{aligned} F_{Y_1}(x) &= \prod_{i=1}^n P\{X_i \leq x\} = (F_X(x))^n \\ F_{Y_n}(x) &= 1 - \prod_{i=1}^n P\{X_i > x\} = 1 - (1 - F_X(x))^n \end{aligned}$$

对于一般的 Y_k , 设有充分小的 b 使得 $x < Y_k \leq x + b$, 即 $k-1$ 个 X_i 落在 $(-\infty, x]$, 1 个 X_i 落在 $(x, x + b]$, 其余 $n-k$ 个 X_i 落在 $(x + b, +\infty)$, 则有

$$\begin{aligned} f_{Y_k}(x) &= \lim_{b \rightarrow 0} \frac{P\{x < Y_k \leq x + b\}}{b} \\ &= \lim_{b \rightarrow 0} \frac{1}{b} \binom{n}{k-1} \binom{n-k+1}{1} \binom{n-k}{n-k} \\ &\quad \cdot (F_X(x))^{k-1} \cdot (F_X(x+b) - F_X(x)) \cdot (1 - F_X(x+b))^{n-k} \\ &= \binom{n}{k-1} \binom{n-k+1}{1} (F_X(x))^{k-1} (1 - F_X(x))^{n-k} f_X(x) \end{aligned}$$

同理, 通过微元法拆分, 可以得到顺序统计量的联合概率密度函数

$$f_{Y_1, Y_2, \dots, Y_n}(y_1, y_2, \dots, y_n) = \begin{cases} n! \prod_{i=1}^n f_X(y_i), & y_1 < y_2 < \dots < y_n, \\ 0, & \text{otherwise} \end{cases}$$

注意到, n 个在 $(0, t)$ 上独立同分布的均匀分布随机变量的顺序统计量的联合概率密度函数与上述条件联合概率密度函数形式完全相同, 因此等待时间 $S_1, S_2, \dots, S_n$ 在条件 $N(t) = n$ 下可视为 n 个在 $(0, t)$ 上独立同分布的均匀分布随机变量的顺序统计量。这意味着, 就总等待时间而言, 可以将 Poisson 过程视为在时间轴上随机均匀分布的事件集合。

对条件联合概率密度函数进行边缘化, 有

$$\begin{aligned} f_{S_k \mid N(t)=n}(s_k) &= \int_0^{s_k} ds_{k-1} \int_0^{s_{k-1}} ds_{k-2} \cdots \int_0^{s_2} ds_1 \cdot \int_{s_k}^t ds_{k+1} \cdots \int_{s_{n-1}}^t ds_n \\ &\quad \cdot f_{S_1, S_2, \dots, S_n \mid N(t)=n}(s_1, s_2, \dots, s_n) \\ &= \frac{n!}{t^n} \cdot \frac{s_k^{k-1}}{(k-1)!} \frac{(t-s_k)^{n-k}}{(n-k)!} \\ &= \frac{1}{t} \frac{n!}{(k-1)!(n-k)!} \left(\frac{s_k}{t}\right)^{k-1} \left(1 - \frac{s_k}{t}\right)^{n-k}, \quad 0 < s_k < t \end{aligned}$$

这即为参数为 $(k, n-k+1, t)$ 的 **Beta 分布 (Beta distribution)**。利用 Beta 函数与 Gamma 函数的关系

$$B(\alpha, \beta) = \int_0^1 t^{\alpha-1} (1-t)^{\beta-1} dt = \frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha+\beta)} \stackrel{\alpha, \beta \in \mathbb{Z}_+}{=} \frac{(\alpha-1)!(\beta-1)!}{(\alpha+\beta-1)!}$$

可得

$$\begin{aligned} \mathbb{E}[S_k \mid N(t) = n] &= \frac{k}{n+1} t, \quad \mathbb{E}[S_k^2 \mid N(t) = n] = \frac{k(k+1)}{(n+1)(n+2)} t^2 \\ \text{Var}[S_k \mid N(t) = n] &= \frac{k(n-k+1)}{(n+1)^2(n+2)} t^2 \end{aligned}$$

► Poisson 过程的推广

■ 非齐次 Poisson 过程

对于某些实际问题, 事件发生的强度并非恒定不变, 而是随着时间变化的。为此, 考虑**削弱 Poisson 过程的增量平稳性**, 即不再有

$$\Delta N(t) = N(t + \Delta t) - N(t) \stackrel{d}{=} N(\Delta t)$$

此时, **矩母函数的导数式**中 $N(\Delta t)$ 应全部保留为 $\Delta N(t)$, 处理 **Term 1** 时不再有 $P\{\Delta N(t) = 0\} = e^{-\lambda \Delta t}$, 我们引入

$$\lim_{\Delta t \rightarrow 0} \frac{1}{\Delta t} (1 - P\{\Delta N(t) = 0\}) = \lambda(t)$$

对 **Term 2**, 仍有

$$\frac{1 - P\{\Delta N(t) = 0\}}{\Delta t} = \frac{P\{\Delta N(t) = 1\}}{\Delta t} \left(1 + \frac{P\{\Delta N(t) \geq 2\}}{P\{\Delta N(t) = 1\}} \right)$$

且仍保留[稀疏性假设](#)

$$\lim_{\Delta t \rightarrow 0} \frac{1}{\Delta t} \frac{P\{\Delta N(t) \geq 2\}}{P\{\Delta N(t) = 1\}} = 0$$

因此有

$$\lim_{\Delta t \rightarrow 0} \frac{1}{\Delta t} P\{\Delta N(t) = 1\} = \lambda(t)$$

这也使得 $\lambda(t)$ 可视为[事件发生速率](#)；类似地，[Term 3](#) 仍为 0，故得到[关于矩母函数的微分方程](#)

$$\frac{d}{dt} G_{N(t)}(z) = (-\lambda(t) + \lambda(t)z) G_{N(t)}(z), \quad G_{N(0)}(z) = 1$$

解得

$$G_{N(t)}(z) = \exp \left(\int_0^t \lambda(\tau) d\tau \cdot (z - 1) \right) = \exp \left(z \int_0^t \lambda(\tau) d\tau \right) \exp \left(- \int_0^t \lambda(\tau) d\tau \right)$$

故得

$$P\{N(t) = k\} = \frac{\left(\int_0^t \lambda(\tau) d\tau \right)^k}{k!} \exp \left(- \int_0^t \lambda(\tau) d\tau \right)$$

当 $\lambda(t)$ 「齐次」为 $\lambda(t) \equiv \lambda$ 时，即得到 Poisson 分布的概率分布，故此分布称为[非齐次 Poisson 过程 \(non-homogeneous Poisson Process\)](#)。

类似于参数为 λ 齐次 Poisson 过程 $N(t)$ 服从[参数为 \$\lambda t\$ 的 Poisson 分布](#)，事件发生速率为 $\lambda(t)$ 的非齐次 Poisson 过程 $N(t)$ 服从[参数为 \$\int_0^t \lambda\(\tau\) d\tau\$ 的 Poisson 分布](#)，有

$$\mathbb{E}[N(t)] = \text{Var}[N(t)] = \int_0^t \lambda(\tau) d\tau$$

■ 复合 Poisson 过程

► 从事件「效果」引入复合 Poisson 过程

考虑[发生次数服从 Poisson 过程](#)的随机过程 $X(t) = \sum_{k=1}^{N(t)} X_k$ ，其中单个事件的「效果」 $\{X_k\}_{k=1}^{\infty}$ 独立同分布且独立于 $N(t)$ 。

已知 $G_{N(t)}(z) = \mathbb{E}[z^{N(t)}] = e^{(-\lambda + \lambda z)t}$ ，则 $X(t)$ 的矩母函数为

$$\begin{aligned} G_{X(t)}(z) &= \mathbb{E}[z^{X(t)}] = \mathbb{E}[z^{\sum_{k=1}^{N(t)} X_k}] = \mathbb{E}_{N(t)} \left[\mathbb{E}_{X_k|N(t)} [z^{\sum_{k=1}^n X_k} \mid N(t) = n] \right] \\ &= \mathbb{E} \left[\left(\mathbb{E}[z^{X_k}] \right)^{N(t)} \right] = G_{N(t)}(G_{X_k}(z)) = e^{(-\lambda + \lambda G_{X_k}(z))t} \end{aligned}$$

可见， $X(t)$ 的[矩母函数](#)（或[特征函数](#)，若 $\{X_k\}_{k=1}^{\infty}$ 取值不为非负整数）为 $N(t)$ 的矩母函数与 $\{X_k\}_{k=1}^{\infty}$ 的矩母函数（或[特征函数](#)）的[复合](#)，因此称为[复合 Poisson 过程 \(compound Poisson process\)](#)。

☞ [ℰℊ. 例题 > L14-1: Poisson 过程的独立稀释](#)

☞ [ℰℊ. 例题 > L14-2: Poisson 过程的和与差](#)

► 从事件稀疏性引入复合 Poisson 过程

另一方面，对于某些实际问题，时间微元内出现 2 次或以上事件的概率不可忽略，需要考虑[削弱 Poisson 稀疏性假设](#)，即设定

$$P\{X(\Delta t) = k \mid X(\Delta t) \geq 1\} \xrightarrow{\Delta t \rightarrow 0} p_k$$

这对 [Term 1](#) 没有影响；对 [Term 2](#)、[Term 3](#)，不再需要分开讨论，有

$$\begin{aligned} &\lim_{\Delta t \rightarrow 0} \frac{1}{\Delta t} \sum_{k=1}^{\infty} P\{X(\Delta t) = k\} \cdot z^k \\ &= \lim_{\Delta t \rightarrow 0} \frac{1}{\Delta t} P\{X(\Delta t) \geq 1\} \cdot \sum_{k=1}^{\infty} P\{X(\Delta t) = k \mid X(\Delta t) \geq 1\} \cdot z^k \\ &= \lim_{\Delta t \rightarrow 0} \frac{1}{\Delta t} (1 - P\{X(\Delta t) = 0\}) \underbrace{\sum_{k=1}^{\infty} p_k z^k}_{P(z)} = \lambda P(z) \end{aligned}$$

即得到[关于矩母函数的微分方程](#)

$$\frac{d}{dt} G_{X(t)}(z) = \lambda(P(z) - 1)G_{X(t)}(z), \quad G_{X(0)}(z) = 1$$

解得

$$G_{X(t)}(z) = \exp(\lambda t(P(z) - 1)) = \exp(\lambda t P(z)) \exp(-\lambda t) = G_{N(t)}(P(z))$$

此即上述复合 Poisson 过程的矩母函数。

■ 过滤 Poisson 过程

在复合 Poisson 过程中，若将事件「效果」看作是由 $\{X_k\}_{k=1}^{\infty}$ 决定的[某个随机系统的输出](#)，则该过程可视为[过滤 Poisson 过程 \(filtered Poisson process\)](#)。设该随机系统的[冲激响应 \(impulse response\)](#) 为 $b(t; x)$ ，则系统输出为

$$Y(t) = \sum_{k=1}^{N(t)} b(t - S_k; X_k)$$

其中 $S_k = \sum_{i=1}^k T_i$ 为第 k 个事件发生的时间， T_i 为事件间隔。

$Y(t)$ 的[特征函数](#)为

$$\begin{aligned} \phi_{Y(t)}(\omega) &= \mathbb{E}[e^{j\omega Y(t)}] = \mathbb{E} \left[\exp \left(j\omega \sum_{k=1}^{N(t)} b(t - S_k; X_k) \right) \right] \\ &= \mathbb{E}_{N(t)} \left[\mathbb{E}_{\{S_k, X_k\}} \left[\exp \left(j\omega \sum_{k=1}^n b(t - S_k; X_k) \right) \mid N(t) = n \right] \right] \\ &= \mathbb{E}_{N(t)} \left[\mathbb{E}_{\{U_k, X_k\}} \left[\prod_{k=1}^n e^{j\omega b(t - U_k; X_k)} \mid N(t) = n \right] \right] \\ &= \mathbb{E}_{N(t)} \left[\left(\int_0^t \mathbb{E}_{X_k} [e^{j\omega b(t - u; X_k)}] \frac{1}{t} du \right)^{N(t)} \right] \\ &\stackrel{\mathbb{E}[e^{N(t)}] = e^{\lambda t(z-1)}}{=} \exp \left(\lambda t \left(\int_0^t \mathbb{E} [e^{j\omega b(t - u; X_k)}] \frac{1}{t} du - 1 \right) \right) \\ &= \exp \left(\lambda \int_0^t (\mathbb{E} [e^{j\omega b(t - u; X_k)}] - 1) du \right) \end{aligned}$$

其中 $\{U_k\}$ 为在 $(0, t)$ 上独立同分布的均匀分布随机变量，其顺序统计量即为条件 $N(t) = n$ 下的 $\{S_k\}$ ，在求和意义下二者等价。

由特征函数，容易得到 $Y(t)$ 的[均值与方差](#)

$$\mathbb{E}[Y(t)] = \lambda \int_0^t \mathbb{E}[b(t - u; X_k)] du, \quad \text{Var}[Y(t)] = \lambda \int_0^t \mathbb{E}[b^2(t - u; X_k)] du$$

若事件的影响是[因果的](#)，即 $b(t; x) = 0$ 对 $t < 0$ 成立，则用类似的方法可以计算过滤 Poisson 过程的二维特征函数

$$\begin{aligned} \phi_{Y(t_1), Y(t_2)}(\omega_1, \omega_2) &= \mathbb{E}[e^{j\omega_1 Y(t_1) + j\omega_2 Y(t_2)}] \\ &= \exp \left(\lambda \int_0^{\max\{t_1, t_2\}} (\mathbb{E}[e^{j\omega_1 b(t_1 - u; X_k) + j\omega_2 b(t_2 - u; X_k)}] - 1) du \right) \end{aligned}$$

从而得到[协方差函数](#)

$$C_Y(t_1, t_2) = \lambda \int_0^{\min\{t_1, t_2\}} \mathbb{E}[b(t_1 - u; X_k)b(t_2 - u; X_k)] du$$

特别地，[波形 \$b\$ 不具有随机性](#)时，有

$$\begin{aligned} \phi_{Y(t)}(\omega) &= \exp \left(\lambda \int_0^t (e^{j\omega b(t - u)} - 1) du \right), \\ \mathbb{E}[Y(t)] &= \lambda \int_0^t b(t - u) du, \quad \text{Var}[Y(t)] = \lambda \int_0^t b^2(t - u) du, \\ C_Y(t_1, t_2) &= \lambda \int_0^{\min\{t_1, t_2\}} b(t_1 - u)b(t_2 - u) du \end{aligned}$$

Markov 链

► Markov 链的定义

[Markov 链](#)是描述[离散时间](#)、[离散状态](#)的随机过程的模型，是具有[Markov 性](#)的离散时间离散状态随机过程。

■ Markov 性

对一个随机过程 $\{X_k\}_{k=0}^\infty$ ，**Markov 性**表述为 $\forall n$

$$P\{X_n = x_n \mid X_{n-1} = x_{n-1}, \dots, X_1 = x_1, X_0 = x_0\} = P\{X_n = x_n \mid X_{n-1} = x_{n-1}\}$$

若称 X_{n-1} 为**现在** (B)，之前的状态为**过去** (A)，之后的状态为**未来** (C)，则 **Markov 性**表明了条件之间的独立性

$$P(CA \mid B) = P(C \mid B)P(A \mid B)$$

「过去」与「未来」之间的联系，只有通过「现在」建立起来。如果掌握了现在，那么过去的信息对于推测未来不起作用。

「过去」和「未来」均可以复杂化，即

- 将未来 X_n **泛化为集合 A** ，有

$$\begin{aligned} &P\{X_n \in A \mid X_{n-1} = x_{n-1}, \dots, X_1 = x_1, X_0 = x_0\} \\ &= \sum_{x_n \in A} P\{X_n = x_n \mid X_{n-1} = x_{n-1}, \dots, X_1 = x_1, X_0 = x_0\} \\ &= \sum_{x_n \in A} P\{X_n = x_n \mid X_{n-1} = x_{n-1}\} = P\{X_n \in A \mid X_{n-1} = x_{n-1}\} \end{aligned}$$

仍然保持 Markov 性；

- 将过去 $(X_{n-2}, \dots, X_0)$ **泛化为集合 B** ，有

$$\begin{aligned} &P\{X_n = x_n, (X_{n-2}, \dots, X_0) \in B \mid X_{n-1} = x_{n-1}\} \\ &= \sum_{\substack{\{x_k\}_{k=0}^{n-2} \in B \\ \text{「未来」}}} P\{X_n = x_n, \underbrace{(X_{n-2}, \dots, X_0) \in (x_{n-2}, \dots, x_0)}_{\text{「过去」}} \mid \underbrace{X_{n-1} = x_{n-1}}_{\text{「现在」}}\} \\ &= \sum_{\substack{\{x_k\}_{k=0}^{n-2} \in B \\ \text{「未来」}}} P\{X_n = x_n \mid \underbrace{X_{n-1} = x_{n-1}}_{\text{「现在」}}\} \\ &\quad \cdot P\{\underbrace{(X_{n-2}, \dots, X_0) \in (x_{n-2}, \dots, x_0)}_{\text{「过去」}} \mid \underbrace{X_{n-1} = x_{n-1}}_{\text{「现在」}}\} \\ &= P\{X_n = x_n \mid X_{n-1} = x_{n-1}\} \cdot P\{(X_{n-2}, \dots, X_0) \in B \mid X_{n-1} = x_{n-1}\} \end{aligned}$$

即

$$\begin{aligned} &P\{X_n = x_n \mid (X_{n-2}, \dots, X_0) \in B, X_{n-1} = x_{n-1}\} \\ &= \frac{P\{X_n = x_n, (X_{n-2}, \dots, X_0) \in B \mid X_{n-1} = x_{n-1}\}}{P\{(X_{n-2}, \dots, X_0) \in B \mid X_{n-1} = x_{n-1}\}} = P\{X_n = x_n \mid X_{n-1} = x_{n-1}\} \end{aligned}$$

仍然保持 Markov 性。

但是，「现在」的复杂化将可能破坏 Markov 性。

Markov 链的迭代表示

我们考虑 Markov 链的 n 维联合概率分布，有

$$\begin{aligned} P(X_n, X_{n-1}, \dots, X_0) &= P(X_n \mid X_{n-1}, \dots, X_0) \cdot P(X_{n-1}, \dots, X_0) \\ &= P(X_n \mid X_{n-1}) \cdot P(X_{n-1}, \dots, X_0) \\ &= \dots \\ &= P(X_n \mid X_{n-1})P(X_{n-1} \mid X_{n-2}) \dots P(X_1 \mid X_0)P(X_0) \end{aligned}$$

即，其决定于一组条件概率

$$P_{i,j}(m, n) = P\{X_n = x_j \mid X_m = x_i\}$$

称为 $n - m$ 步**转移概率 (transition probability)**。

平稳转移概率假设

一般地，一个 n 步的转移概率 $P_{i,j}(m, m+n)$ 与其发生的时刻 m 有关。如果其**与发生时刻无关**，即

$$\forall m, \quad P_{i,j}(m, m+n) \equiv P_{i,j}(n)$$

则称之为**平稳 (stationary)** Markov 链。

在此假设下，特定步数 n 的转移概率只依赖于转移的**起点状态 i** 和**终点状态 j** ，计算 $P_{i,j}^{(n)}$ 只需对起点与终点之间的每一条路径的概率求和即可，尽管也不是非常简便。

Chapman-Kolmogorov 方程

Thm. Chapman-Kolmogorov 方程

设 Markov 链的状态空间为 E ， $i, j, k \in E$ ，对时刻 r, s, t ，有

$$P_{i,j}(r, t) = \sum_k P_{i,k}(r, s)P_{k,j}(s, t)$$

在**平稳转移概率假设**下，对时间间隔 m, n ，有

$$P_{i,j}(m+n) = \sum_k P_{i,k}(m)P_{k,j}(n)$$

C-K 方程的本质是将路径求和**按照中间时刻 s (或中间步数 m) 的状态 k 分组**，因此显然是一个恒等式。具体地，

$$\begin{aligned} P_{i,j}(m+n) &= P\{X_{m+n} = x_j \mid X_0 = x_i\} \\ &= \sum_k P\{X_{m+n} = x_j, X_m = x_k \mid X_0 = x_i\} \\ &= \sum_k P\{X_{m+n} = x_j \mid X_m = x_k, X_0 = x_i\}P\{X_m = x_k \mid X_0 = x_i\} \\ &= \sum_k \underbrace{P\{X_{m+n} = x_j \mid X_m = x_k\}}_{P_{k,j}(n)} \underbrace{P\{X_m = x_k \mid X_0 = x_i\}}_{P_{i,k}(m)} \end{aligned}$$

容易发现，**C-K 方程**的形式类似**矩阵乘法**，由此定义

$$\mathbf{P}(n) = \left(P_{i,j}(n)\right)_{i,j}$$

称为 n 步**转移概率矩阵**，则立得

$$\mathbf{P}(m+n) = \mathbf{P}(m)\mathbf{P}(n)$$

于是，任意步数 n 的转移概率矩阵为

$$\mathbf{P}(n) = \mathbf{P}(n-1)\mathbf{P}(1) = \mathbf{P}(n-2)(\mathbf{P}(1))^2 = \dots (\mathbf{P}(1))^n$$

因此，只要给定

- 1 步转移概率矩阵 $\mathbf{P}(1) = (P_{i,j}(1))_{i,j}$** ，不妨记为 **$\mathbf{P}$** ，以及
- 初始概率分布 $\{P\{X_0 = x_i\}\}_i$** ，

则整个 Markov 链的概率分布就确定了。

Markov 链的常返性

从 Markov 性的「精神」出发，当转移步数 n 即**时间趋于无穷**时，我们希望 Markov 链达到一个**不依赖初始状态的稳定分布**，即希望有

$$P_{i,j}(n) \xrightarrow{n \rightarrow \infty} P_j$$

Markov 链状态的分类

我们期望深入考察 Markov 链的状态空间结构，为此将**状态值 x_i** 简记为 **i** ，并给出如下几个定义：

- 若 $\exists n > 0$ ， $P_{i,j}(n) > 0$ ，则称 **i 可达 (reachable) j** ，记作 $i \rightarrow j$ ；
- 若 $i \rightarrow j$ 且 $j \rightarrow i$ ，则称 **i, j 相通 (commutative)**，记作 $i \leftrightarrow j$ ；
- 如果对集合 $S \subseteq E$ ， $\forall i \in S, j \notin S, i \nrightarrow j$ ，则称 S 为**闭集 (closed set)**。

Def. 不可约 Markov 链

设 Markov 链的状态空间为 E ，如果子集 $C \subseteq E$ 仅有一个**闭集 C** 本身，即不存在闭的真子集，则称该子集为**不可约 (irreducible)** 的。

如果状态空间 E 本身是不可约的，则称该 Markov 链为不可约的。

设 $C \subseteq E$ 不可约，我们设 $\forall i \in C, A_i = \{j \in C \mid i \rightarrow j\}$ 为 i 可达的状态集合，现在我们证明 A_i 是闭集，从而得到 $A_i = C$ 。 $\forall j \in A_i$ ，假定 $\exists k \notin A_i$ ，使得 $j \rightarrow k$ ，则由 $i \rightarrow j$ 和 $j \rightarrow k$ 可知 $i \rightarrow k$ ，从而 $k \in A_i$ ，与假设矛盾，因此 A_i 是闭集，只能有 $A_i = C$ 。因此，**不可约 Markov 链中任意两个状态相通**。

常返

设 Markov 链的状态空间为 E ，对 $i, j \in E$ ，定义从时刻 $n = 0$ 出发到达状态 j 的**首达时间 (first passage time)** 为

$$\tau_j = \inf \{n \geq 1 \mid X_n = j\}$$

经 n 步从状态 i 到状态 j 的**首达概率 (first passage probability)** 为

$$\begin{aligned} f_{i,j}(n) &= P\{\tau_j = n \mid X_0 = i\} \\ &= P\{X_1 \neq j, X_2 \neq j, \dots, X_{n-1} \neq j, X_n = j \mid X_0 = i\} \end{aligned}$$

显然，在哪一步首达的事件之间是互斥的，因此有

$$f_{i,j} = \sum_{n=1}^{\infty} f_{i,j}(n) \leq 1$$

$f_{i,j}$ 即为**从状态 i 出发「迟早」到达状态 j 的概率**。

Def. 常返性

对 Markov 链的状态空间 E 中的状态 i ，如果 $f_{i,i} = 1$ ，则称状态 i 为常返 (recurrent) 态；否则， $f_{i,i} < 1$ ，称为滑过 (transient) 态或非常返态。从常返态 i 出发，将以概率 1 返回到状态 i 一次；而从非常返态 i 出发，有正的概率永远不返回状态 i 。

常返性的判据

我们期望利用转移概率 $P_{i,j}(n)$ 来研究 $f_{i,j}(n)$ ，以判定状态 i 的常返性。类比为 C-K 方程的推导，我们可以将 $P_{i,j}(n)$ 按照首达时间 τ_j 分组，有

$$\begin{aligned} P_{i,j}(n) &= P\{X_n = j \mid X_0 = i\} = \sum_{k=1}^n P\{X_n = j, \tau_j = k \mid X_0 = i\} \\ &= \sum_{k=1}^n P\{X_n = j \mid \tau_j = k, X_0 = i\} \cdot P\{\tau_j = k \mid X_0 = i\} \\ &= \sum_{k=1}^n P\{X_n = j \mid X_k = j\} \cdot P\{\tau_j = k \mid X_0 = i\} \\ &= \sum_{k=1}^n P_{j,j}(n-k) f_{i,j}(k) \end{aligned}$$

即

$$P_{i,j}(n) = \sum_{k=1}^n P_{j,j}(n-k) f_{i,j}(k)$$

上式表现出离散时间索引的卷积形式，因此可做 z 变换，定义其生成函数为

$$\tilde{P}_{i,j}(z) = \sum_{n=0}^{\infty} P_{i,j}(n) z^n = \delta_{i,j} + \sum_{n=1}^{\infty} P_{i,j}(n) z^n, \quad F_{i,j}(z) = \sum_{n=1}^{\infty} f_{i,j}(n) z^n$$

则有

$$\begin{aligned} \tilde{P}_{i,j}(z) &= \delta_{i,j} + \sum_{n=1}^{\infty} \sum_{k=1}^n P_{j,j}(n-k) f_{i,j}(k) \cdot z^n \\ &= \delta_{i,j} + \sum_{k=1}^{\infty} \sum_{n=k}^{\infty} (f_{i,j}(k) z^k) (P_{j,j}(n-k) z^{n-k}) \\ &= \delta_{i,j} + \left(\sum_{k=1}^{\infty} f_{i,j}(k) z^k \right) \left(\sum_{m=0}^{\infty} P_{j,j}(m) z^m \right) = \delta_{i,j} + F_{i,j}(z) \tilde{P}_{j,j}(z) \end{aligned}$$

即

$$\tilde{P}_{i,j}(z) = \delta_{i,j} + F_{i,j}(z) \tilde{P}_{j,j}(z)$$

Note Markov 链的分解

Markov 链有两种分解方案：

- 在空间上分解，按照先走 m 步时的中间状态 k 分组，得到

$$P_{i,j}(n) = \sum_k P_{i,k}(m) P_{k,j}(n-m) \quad \text{OR} \quad \mathbf{P}(m+n) = \mathbf{P}(m) \mathbf{P}(n)$$

即 C-K 方程；

- 在时间上分解，按照首达时间分组，得到上式

$$P_{i,j}(n) = \sum_{k=1}^n P_{j,j}(n-k) f_{i,j}(k) \quad \text{OR} \quad \tilde{P}_{i,j}(z) = \delta_{i,j} + F_{i,j}(z) \tilde{P}_{j,j}(z)$$

从而，令 $i = j$ 并令 $z \rightarrow 1_-$ ，得

$$\sum_{n=0}^{\infty} P_{i,i}(n) = \tilde{P}_{i,i}(1_-) = \frac{1}{1 - \sum_{n=1}^{\infty} f_{i,i}(n)} = \frac{1}{1 - f_{i,i}}$$

$f_{i,i}$ 是否为 1 取决于左侧级数 $\sum_{n=0}^{\infty} P_{i,i}(n)$ 的敛散性，由此给出常返性的第一判据。

Thm. 常返性判据

状态 i 为常返态的充分必要条件为级数 $\sum_{n=0}^{\infty} P_{i,i}(n)$ 发散。

当 $i \neq j$ 时，令 $z \rightarrow 1_-$ 则得到

$$\sum_{n=0}^{\infty} P_{i,j}(n) = \tilde{P}_{i,j}(1_-) = F_{i,j}(1_-) \tilde{P}_{j,j}(1_-) = f_{i,j} \sum_{n=0}^{\infty} P_{j,j}(n)$$

若 j 不是常返态，则由判据有 $\sum_{n=0}^{\infty} P_{j,j}(n) < \infty$ ，且由 $f_{i,j} \leq 1$ 亦知

$\sum_{n=0}^{\infty} P_{i,j}(n) < \infty$ ，则二者的通项

$$P_{j,j}(n) \xrightarrow{n \rightarrow \infty} 0, \quad P_{i,j}(n) \xrightarrow{n \rightarrow \infty} 0$$

这也是我们主要研究常返态的原因。

态的返回次数

对常返态 i ，定义其返回次数 $N_i = \#\{n \mid X_n = i, X_0 = i\}$ ，则 N_i 的期望为

$$\mathbb{E}[N_i] = \mathbb{E}\left[\sum_{n=0}^{\infty} \mathbb{1}_{\{X_n=i \mid X_0=i\}}\right] = \sum_{n=0}^{\infty} \mathbb{E}[\mathbb{1}_{\{X_n=i \mid X_0=i\}}] = \sum_{n=0}^{\infty} P_{i,i}(n) = \infty$$

记从 i 到达 j 至少 n 次的概率为

$$g_{i,j}(n) = P\{\# \{k \mid X_k = j\} \geq n \mid X_0 = i\}$$

利用 Markov 链的时间分解，可知

$$\begin{aligned} g_{i,j}(n) &= \sum_{m=1}^{\infty} P\{\tau_j = m, \#\{k > m \mid X_k = j\} \geq n-1 \mid X_0 = i\} \\ &= \sum_{m=1}^{\infty} P\{\tau_j = m \mid X_0 = i\} \cdot P\{\#\{k > m \mid X_k = j\} \geq n-1 \mid X_m = j\} \\ &= \sum_{m=1}^{\infty} P\{\tau_j = m \mid X_0 = i\} \cdot P\{\#\{k \mid X_k = j\} \geq n-1 \mid X_0 = j\} \\ &= \sum_{m=1}^{\infty} f_{i,j}(m) \cdot g_{j,j}(n-1) = f_{i,j} \cdot g_{j,j}(n-1) \end{aligned}$$

令 $i = j$ ，则有递推关系

$$g_{i,i}(n) = f_{i,i} \cdot g_{i,i}(n-1)$$

由 $g_{i,i}(0) = 1$ 可得

$$P\{N_i = n\} = g_{i,i}(n) = (f_{i,i})^n \xrightarrow{n \rightarrow \infty} \begin{cases} 1, & \text{if } f_{i,i} = 1, \\ 0, & \text{if } f_{i,i} < 1 \end{cases}$$

因此，常返态几乎必然无限次返回，而非常返态则几乎必然有限次返回。

常返性与连通性

下面考虑 $i \leftrightarrow j$ ，即 i, j 相通的情况。由 $i \rightarrow j$ ，可知 $\exists m$ 使得 $P_{i,j}(m) > 0$ ；由 $j \rightarrow i$ ，可知 $\exists n$ 使得 $P_{j,i}(n) > 0$ 。因此，对于任意 k ，都有

$$P_{i,i}(m+n+k) \geq P_{i,j}(m) P_{j,j}(k) P_{j,i}(n)$$

即

$$\sum_{k=0}^{\infty} P_{i,i}(m+n+k) \geq P_{i,j}(m) P_{j,i}(n) \sum_{k=0}^{\infty} P_{j,j}(k)$$

若 j 为常返态，则由判据知右侧发散，因此左侧亦发散，从而 $\sum_{k=0}^{\infty} P_{i,i}(k)$ 发散，由判据知 i 亦为常返态，故

Thm. 连通状态的常返性

Markov 链中连通状态的常返性相同。

对有限状态 Markov 链，倘若所有状态都非常返态，则取定 $\forall i \in E$ 都有

$$\forall j \in E, \quad P_{i,j}(n) \xrightarrow{n \rightarrow \infty} 0 \implies \sum_{j \in E} P_{i,j}(n) \xrightarrow{n \rightarrow \infty} 0$$

但由概率归一性知 $\sum_{j \in E} P_{i,j}(n) = 1$ ，与上式矛盾，因此有限状态 Markov 链中至少存在一个常返态。进而，有限不可约 Markov 链中所有状态均为常返态。

进一步考察任意 Markov 链（也只剩无限状态的情况了），设其存在一个常返态 i ，则知 $g_{i,i}(\infty) = 1$ 。对此概率表示的「返回无穷次」的路径加以空间分解，有

$$\begin{aligned} 1 = g_{i,i}(\infty) &= \sum_{k \in E} P_{i,k}(m) \cdot P\{\# \{n > m \mid X_n = i\} = \infty \mid X_m = k\} \\ &= \sum_{k \in E} P_{i,k}(m) \cdot g_{k,i}(\infty), \quad \forall m > 0 \end{aligned}$$

而知 $\sum_{k \in E} P_{i,k}(m) = 1$ ，因此 $\sum_{k \in E} P_{i,k}(m) \cdot (1 - g_{k,i}(\infty)) = 0$ ，这一求和中每一项均非负，故必有

$$\forall m > 0, \quad \forall k \in E, \quad P_{i,k}(m) \cdot (1 - g_{k,i}(\infty)) = 0$$

对于 i 的某一可达状态 j ，由 $i \rightarrow j$ 可知 $\exists m$ 使得 $P_{i,j}(m) > 0$ ，因此 $g_{j,i}(\infty) = 1$ ，即 $j \rightarrow i$ ，从而 $i \leftrightarrow j$ 且 j 亦为常返态。

Thm. 可达状态的常返性

若 Markov 链中存在常返态 i ，则 i 的所有可达状态均与 i 相通，且均为常返态。

转移概率的极限行为

Markov 链的周期性

Def. 周期态

对状态 i ，定义其周期 (period) 为

$$d_i = \gcd \{n \geq 1 \mid P_{i,i}(n) > 0\}$$

其中 gcd 表示最大公约数 (greatest common divisor)。

如果 $d_i = 1$ ，则称状态 i 为非周期 (aperiodic) 态；否则， $d_i \geq 2$ ，称为周期 (periodic) 态。

非周期带来的一个直观性质是

$$\exists N, \quad \forall n \geq N, \quad P_{i,i}(n) > 0$$

考虑两个相通状态 i, j ，即设 $\exists m$ 使得 $P_{i,j}(m) > 0$ ，同时 $\exists n$ 使得 $P_{j,i}(n) > 0$ ，因此

- $P_{i,i}(m+n) \geq P_{i,j}(m)P_{j,i}(n) > 0$ ，故 $d_i \mid (m+n)$ ；
- $\forall k \in \{n \geq 1 \mid P_{j,j}(n) > 0\}$ ，有 $P_{i,i}(m+k+n) \geq P_{i,j}(m)P_{j,j}(k)P_{j,i}(n) > 0$ ，故 $d_i \mid (m+k+n)$ 。

由此， $\forall k \in \{n \geq 1 \mid P_{j,j}(n) > 0\}$ ， $d_i \mid k$ ，即 d_i 是该集合的一个公约数，故 $d_i \mid d_j$ 。同理可得 $d_j \mid d_i$ ，因此 $d_i = d_j$ ，即相通状态的周期性相同。

这样，在不可约 Markov 链中，所有状态的周期性均相同。若其中有一个状态为非周期态，则所有状态均为非周期态，称该 Markov 链为非周期的，并有

$$\exists N, \quad \forall n \geq N, \quad \forall i, j \in E, \quad P_{i,j}(n) > 0$$

遍历性

在非周期的不可约 Markov 链中，直接有

$$\lim_{n \rightarrow \infty} P_{i,j}(n) = \pi_j$$

称为遍历性 (ergodicity) 定理，其中 π_j 与初始状态 i 无关。

若没有非周期的条件，而是在任意不可约 Markov 链中任取两个状态 i, j ，有

$$\lim_{n \rightarrow \infty} \frac{1}{n} \sum_{k=1}^n P_{i,j}(k) = \frac{1}{a_j}$$

称为弱遍历性 (weak ergodicity) 定理，其中 $a_j = \sum_{k=1}^{\infty} f_{i,i}(k) \cdot k$ 为状态 j 的平均返回时间 (mean return time)，与初始状态 i 无关。由级数知识知，若存在

$$\lim_{n \rightarrow \infty} P_{i,j}(n) = \pi_j, \quad \text{则} \quad \frac{1}{a_j} = \lim_{n \rightarrow \infty} \frac{1}{n} \sum_{k=1}^n P_{i,j}(k) = \pi_j.$$

另外，此处 $\frac{1}{n} \sum_{k=1}^n P_{i,j}(k)$ 可写成

$$\begin{aligned} \frac{1}{n} \sum_{k=1}^n P_{i,j}(k) &= \frac{1}{n} \sum_{k=1}^n \mathbb{E}[\mathbb{1}_{\{X_k=j \mid X_0=i\}}] = \frac{1}{n} \mathbb{E} \left[\sum_{k=1}^n \mathbb{1}_{\{X_k=j \mid X_0=i\}} \right] \\ &= \frac{\mathbb{E}[\#\{k \mid X_k=j, X_0=i, 1 \leq k \leq n\}]}{n} \end{aligned}$$

其概率意义是在 n 步转移中到达状态 j 的平均频率，即 n 步转移中状态 j 的平均比例。

正常返、零常返

考虑上述「平均到达频率」的极限 $\lim_{n \rightarrow \infty} \frac{1}{n} \sum_{k=1}^n P_{i,j}(k)$ ，其与初始状态无关，因此也可称为「平均返回频率」。由非常返态的性质知，若状态 j 为非常返态，则 $P_{i,j}(n) \xrightarrow{n \rightarrow \infty} 0$ ，从而 $\lim_{n \rightarrow \infty} \frac{1}{n} \sum_{k=1}^n P_{i,j}(k) = 0$ ，即平均返回频率为 0。

但对于常返态，并不一定有正的平均频率，定义：

- 若状态 j 的平均返回时间有限，即 $a_j < \infty$ ，则 $\lim_{n \rightarrow \infty} \frac{1}{n} \sum_{k=1}^n P_{i,j}(k) = \frac{1}{a_j} > 0$ ，称状态 j 为正常返 (positive recurrent) 态；
- 若状态 j 的平均返回时间无限，即 $a_j = \infty$ ，则 $\lim_{n \rightarrow \infty} \frac{1}{n} \sum_{k=1}^n P_{i,j}(k) = 0$ ，称状态 j 为零常返 (null recurrent) 态。

Ex. 零常返的实例

考虑例题 > L19-1 的一维无限制随机游走，已知当 $p = \frac{1}{2}$ 时状态 0（以及其他所有状态）为常返态，但有

$$P(z) = \sum_{n=0}^{\infty} P_{0,0}(2n) z^{2n} = \sum_{n=0}^{\infty} \binom{2n}{n} \left(\frac{1}{2}\right)^{2n} z^{2n} = \frac{1}{\sqrt{1-z^2}}$$

于是

$$\lim_{n \rightarrow \infty} \frac{1}{n} \sum_{k=1}^n P_{0,0}(k) = \lim_{z \rightarrow 1-} (1-z)P(z) = \lim_{z \rightarrow 1-} \frac{1-z}{\sqrt{1-z^2}} = 0$$

因此，常返态中亦可存在平均返回频率为 0 的情况。

平稳分布

由 C-K 方程， $P(n)$ 有分解

$$P(n) = P(n-1)P(1) = P(1)P(n-1)$$

因此，若极限 $\lim_{n \rightarrow \infty} P(n) = \Pi$ 存在，则有

$$\Pi = \Pi P, \quad \text{and} \quad \Pi = P \Pi$$

其中，

- $\Pi = \lim_{n \rightarrow \infty} P(n)$ 显然应与初状态无关，即形如

$$\Pi = \begin{pmatrix} \pi_1 & \pi_2 & \pi_3 & \cdots \\ \pi_1 & \pi_2 & \pi_3 & \cdots \\ \vdots & \vdots & \vdots & \vdots \\ \pi_1 & \pi_2 & \pi_3 & \cdots \end{pmatrix} = \vec{1}^T (\pi_1 \quad \pi_2 \quad \pi_3 \quad \cdots) = \vec{1}^T \vec{\pi}$$

- 1 步转移概率矩阵 $P = P(1) = (P_{i,j}(1))_{i,j}$ 的各行表示从各状态出发的概率分布，因此各行和均为 1，即 $P \vec{1}^T = \vec{1}^T$ 。

由此 $\Pi \equiv P \Pi$ 成为恒等式，而 $\Pi = \Pi P$ 则可展开为

$$\vec{\pi} = \vec{\pi} P$$

注意此处的 $\vec{\pi}$ 是行向量。

首先确认 $\vec{\pi}$ 非零解的存在性。对（更熟悉的列向量形式的）方程 $(P^T - I)\vec{\pi}^T = \vec{0}^T$ ，考虑 P 的特征方程

$$\det(P^T - \lambda I) = \det(P - \lambda I) = 0$$

由概率矩阵的性质知 $\mathbf{P}\mathbf{1}^T = \mathbf{1}^T$ ，即 $\lambda = 1$ 是其特征值， $\det(\mathbf{P}^T - \mathbf{I}) = 0$ ，从而 **齐次线性方程组有非零解**。

进一步，向量中各元素 $\pi_j = \sum_i \pi_i P_{i,j}(1)$ 。当**初始分布** $P(X_0 = i)$ 即为 π_i 时，有

$$P(X_1 = j) = \sum_i P(X_0 = i)P_{i,j}(1) = \sum_i \pi_i P_{i,j}(1) = \pi_j$$

即**经过一步转移后分布不变**，这是称 π 为 Markov 链的**平稳分布 (stationary distribution)** 的原因。

† 连续时间 Markov 链

设有随机过程 $X(t)$ ，其状态空间记为 $E = \{1, 2, \dots\}$ ，其 **Markov 性** 定义为

$$\forall t_1 \leq t_2 \leq \dots \leq t_n, \quad P\{X(t_n) = x_n \mid X(t_{n-1}) = x_{n-1}, \dots, X(t_1) = x_1\} \\ = P\{X(t_n) = x_n \mid X(t_{n-1}) = x_{n-1}\}$$

满足上述性质的随机过程称为**连续时间 Markov 链 (continuous-time Markov chain, CTMC)**。

■ 转移概率与生成元矩阵

连续时间 Markov 链的**转移概率**定义为

$$P_{i,j}(t) = P\{X(t+s) = j \mid X(s) = i\}, \quad \forall s, t \geq 0$$

由于状态离散，与离散时间 Markov 链类似可定义 $\mathbf{P}(t) = (P_{i,j}(t))_{i,j}$ ，且同样有 **Chapman-Kolmogorov 方程**

$$\mathbf{P}(t+s) = \mathbf{P}(t)\mathbf{P}(s)$$

不同于离散时间 Markov 链，连续时间 Markov 链没有「1 步转移」的概念，其转移概率矩阵 $\mathbf{P}(t)$ 随时间 t **连续变化**。因此，我们考察

$$\lim_{\Delta t \rightarrow 0} \frac{\mathbf{P}(t + \Delta t) - \mathbf{P}(t)}{\Delta t} = \lim_{\Delta t \rightarrow 0} \frac{\mathbf{P}(t)\mathbf{P}(\Delta t) - \mathbf{P}(t)}{\Delta t} = \mathbf{P}(t) \cdot \lim_{\Delta t \rightarrow 0} \frac{\mathbf{P}(\Delta t) - \mathbf{I}}{\Delta t} \\ = \lim_{\Delta t \rightarrow 0} \frac{\mathbf{P}(\Delta t)\mathbf{P}(t) - \mathbf{P}(t)}{\Delta t} = \lim_{\Delta t \rightarrow 0} \frac{\mathbf{P}(\Delta t) - \mathbf{I}}{\Delta t} \cdot \mathbf{P}(t)$$

定义**生成元矩阵 (generator matrix)** 为

$$\mathbf{Q} = \lim_{\Delta t \rightarrow 0} \frac{\mathbf{P}(\Delta t) - \mathbf{I}}{\Delta t}$$

则有 **Kolmogorov 前向方程与后向方程**

$$\begin{cases} \frac{d}{dt}\mathbf{P}(t) = \mathbf{P}(t)\mathbf{Q} & (\text{前向方程}) \\ \frac{d}{dt}\mathbf{P}(t) = \mathbf{Q}\mathbf{P}(t) & (\text{后向方程}) \end{cases}$$

于是， $\mathbf{P}(t)$ 的演化由 $\mathbf{Q}$ 决定，有

$$\mathbf{P}(t) = \mathbf{P}(0)e^{\mathbf{Q}t} = \mathbf{P}(0) \sum_{n=0}^{\infty} \frac{(\mathbf{Q}t)^n}{n!} = \mathbf{P}(0) \sum_{n=0}^{\infty} \frac{t^n}{n!} \mathbf{Q}^n$$

$\mathbf{Q}$ 有以下性质：

- 其**非对角元非负**，即 $Q_{i,j} \geq 0, \forall i \neq j$ ，表示单位时间内从状态 i 转移到状态 j 的速率；
- 其**对角元为负**，保证**行和为 0**，即 $Q_{i,i} = -\sum_{j \neq i} Q_{i,j} \leq 0$ ，表示单位时间内**离开状态 i** 的速率。

⌘ E.G. Poisson 过程的生成元矩阵

Poisson 过程即是一个典型的连续时间 Markov 链，由**稀疏性假设**，其在 $\Delta t \rightarrow 0$ 间隔内的转移概率为

$$P_{i,j}(\Delta t) = \begin{cases} e^{-\lambda \Delta t}, & j = i, \\ \lambda \Delta t \cdot e^{-\lambda \Delta t}, & j = i + 1, \\ 0, & \text{otherwise} \end{cases}$$

因此，其生成元矩阵的矩阵元为

$$Q_{i,j} = \lim_{\Delta t \rightarrow 0} \frac{P_{i,j}(\Delta t) - \delta_{i,j}}{\Delta t} = \begin{cases} -\lambda, & j = i, \\ \lambda, & j = i + 1, \\ 0, & \text{otherwise} \end{cases}$$

即生成元矩阵为

$$\mathbf{Q} = \begin{pmatrix} -\lambda & \lambda & & \\ & -\lambda & \lambda & \\ & & -\lambda & \lambda \\ & & & \ddots & \ddots \end{pmatrix}$$

■ 平稳分布

不同于离散时间 Markov 链，对连续时间 Markov 链，只要**不可约**，则 $P_{i,j}(t)$ 的极限 $\lim_{t \rightarrow \infty} P_{i,j}(t) = \pi_j$ 总是存在，且与初始状态 i 无关。因此， $\mathbf{P}(t)$ 的极限 $\lim_{t \rightarrow \infty} \mathbf{P}(t) = \mathbf{\Pi}$ 亦存在，且形如

$$\mathbf{\Pi} = \begin{pmatrix} \pi_1 & \pi_2 & \pi_3 & \cdots \\ \pi_1 & \pi_2 & \pi_3 & \cdots \\ \vdots & \vdots & \vdots & \vdots \\ \pi_1 & \pi_2 & \pi_3 & \cdots \end{pmatrix} = \mathbf{1}^T \pi$$

由 Kolmogorov 前向方程知

$$\mathbf{0} = \lim_{t \rightarrow \infty} \frac{d}{dt} \mathbf{P}(t) = \lim_{t \rightarrow \infty} \mathbf{P}(t)\mathbf{Q} = \mathbf{\Pi}\mathbf{Q} \implies \pi\mathbf{Q} = \mathbf{0}$$

同样需注意此处向量符号默认是**行向量**。

与离散时间 Markov 链类似， π 是连续时间 Markov 链的**平稳分布**，当初始分布为 π 时，经过任意时间 t 的转移后分布仍为 π 。

1. 陆大鈺，张颢：《随机过程及其应用》，北京：清华大学出版社，2012 年，p. 5。